

BURNOUTGUARD: SISTEMA DE DETECCIÓN TEMPRANA DE RIESGO DE BURNOUT

MASTER IN BIG DATA AND BUSINESS INTELLIGENCE

TRABAJO DE FIN DE MÁSTER

Daniel Vargas Salazar

David Mejía Cascante

Juan Luis Chávez Mejía

María Cubero Sandoval

Melany Jiménez Nin

Director del Máster: Belarmino García

Tutor del TFM: Mariano Muñoz

En Madrid, a 18 de Junio 2026

ÍNDICE

1. Resumen.....	4
2. Introducción.....	5
Antecedentes.....	5
Justificación.....	6
Problema de investigación.....	7
Hipótesis.....	8
Objetivos de Investigación.....	9
Metodología.....	9
Marco Teórico.....	10
Alcance y limitaciones.....	14
3. Estado de la cuestión.....	15
Conceptualización del síndrome de burnout.....	15
Modelos teóricos del estrés laboral.....	15
Copenhagen Burnout Inventory.....	15
Burnout en la profesión veterinaria.....	16
Business Intelligence y People Analytics.....	17
Machine Learning aplicado a salud organizacional.....	17
Visualización de datos organizacionales.....	18
4. Desarrollo Metodológico.....	19
Diseño de investigación.....	19
Dataset principal y datasets complementarios.....	19
Flujo de datos.....	21
Preparación y transformación de datos.....	22
Herramientas tecnológicas.....	24

Desarrollo de dashboards en Tableau	25
Modelos de Machine Learning	26
Variables utilizadas en el modelo completo.....	26
División de datos y preprocesamiento dentro del pipeline	27
Entrenamiento y optimización de modelos	28
Evaluación del desempeño e importancia de variables	29
5. Análisis y resultados	31
Análisis Univariante del EDA.....	31
Análisis Bivariante del EDA	35
Dashboard informativo en Tableau	42
Machine Learning	47
Resultados	47
Análisis e interpretación.....	54
6. Conclusiones.....	57
7. Bibliografía	61
8. Anexos.	67

1. RESUMEN

El presente Trabajo Final de Máster se desarrolla una propuesta de sistema analítico orientado a la detección temprana del riesgo de burnout laboral mediante la integración de técnicas de Business Intelligence, análisis exploratorio de datos, visualización interactiva en Tableau Desktop y modelos supervisados de Machine Learning. El estudio utiliza como fuente principal un dataset de 3181 registros correspondientes a profesionales veterinarios en Alemania, con información sociodemográfica, laboral y psicométrica basada en el Copenhagen Burnout Inventory (CBI).

La metodología comprende la recolección, depuración y transformación de datos, el análisis exploratorio, el modelado relacional, el desarrollo de dashboards y la evaluación de modelos predictivos para la clasificación del riesgo de burnout. Los resultados evidencian que la integración de variables laborales, sociodemográficas y psicométricas permite identificar patrones relevantes asociados al agotamiento profesional. En conjunto, BurnoutGuard se plantea como una aproximación viable para apoyar procesos de People Analytics, visualización estratégica y gestión preventiva del bienestar organizacional.

2. INTRODUCCIÓN

Antecedentes

El interés por el estudio del burnout ha aumentado significativamente durante los últimos años debido a las consecuencias observadas tanto en la salud de los trabajadores como en el desempeño organizacional. Diversos estudios han evidenciado que exposición prolongada a factores de estrés laboral incrementa el riesgo de agotamiento emocional y disminuye la productividad (Maslach et al., 2001; Salvagioni et al., 2017).

La Organización Mundial de la Salud (OMS) incorporó oficialmente el burnout dentro de la Clasificación Internacional de Enfermedades (CIE-11) como un fenómeno ocupacional asociado al estrés laboral crónico no gestionado adecuadamente (World Health Organization, 2019). Esta incorporación consolidó el interés académico y empresarial por desarrollar mecanismos de prevención y detección temprana.

Paralelamente, el crecimiento de disciplinas como Big Data, Business Intelligence y People Analytics ha permitido que las organizaciones evolucionen hacia modelos de toma de decisiones basados en datos (Davenport et al., 2010; Marler & Boudreau, 2017). En este contexto, las áreas de recursos humanos han comenzado a incorporar herramientas analíticas orientadas a comprender fenómenos relacionados con el desempeño laboral, el bienestar organizacional y la retención del talento.

Diversas investigaciones han identificado que profesiones vinculadas con alta carga emocional presentan una mayor prevalencia de agotamiento profesional. Entre estas ocupaciones destaca el gremio veterinario, caracterizado por jornadas extensas, presión emocional, toma constante de decisiones críticas y exposición frecuente a situaciones de desgaste psicológico (Mastenbroek et al., 2014; Moses et al., 2018).

La convergencia entre analítica de datos y salud organizacional ha impulsado el desarrollo de investigaciones orientadas a construir sistemas predictivos

capaces de identificar riesgos psicosociales antes de que se materialicen en consecuencias operativas severas (Boudreau & Cascio, 2017).

Justificación

La relevancia de esta investigación radica en la necesidad de desarrollar mecanismos preventivos que permitan identificar oportunamente factores asociados al burnout. En lugar de actuar cuando las consecuencias ya son visibles, las organizaciones pueden beneficiarse de modelos analíticos que apoyen la toma de decisiones basadas en evidencia.

Desde una perspectiva empresarial, la detección tardía del burnout genera costos significativos relacionados con ausentismo, rotación de personal, disminución del rendimiento y deterioro del clima organizacional (Salvagioni et al., 2017). A pesar de ello, numerosas organizaciones continúan utilizando enfoques reactivos basados únicamente en evaluaciones periódicas o intervenciones posteriores al deterioro del bienestar laboral.

En términos académicos, existe una oportunidad relevante para integrar herramientas de analítica predictiva y visualización de datos dentro de la gestión preventiva de riesgos psicosociales. La combinación entre Business Intelligence y Machine Learning está orientado al análisis de la información operativa y psicométrica para apoyar la toma de decisiones (Sharda et al., 2023).

Más allá del componente psicológico, el burnout tiene una clara dimensión económica para las organizaciones. Desde la teoría del capital humano se entiende que cada empleado representa una inversión específica de la empresa en formación y experiencia, inversión que se deteriora cuando las condiciones laborales producen agotamiento sostenido (Becker, 1964). La teoría de los salarios de eficiencia (Akerlof y Yellen, 1990) llega a una conclusión fusionada: un entorno laboral percibido como injusto o desequilibrado termina traducándose en menor productividad, mayor rotación voluntaria y un menor retorno sobre la formación entregada. Estudios internacionales confirman que estos costos son considerables, abarcando gastos médicos directos,

ausentismo, rotación y pérdidas de productividad asociadas al presentismo (Hassard et al., 2018).

El proyecto BurnoutGuard integra herramientas metodológicas y tecnológicas que combina procesamiento de datos, análisis exploratorio y modelos supervisados para identificar patrones asociados al riesgo de burnout laboral.

Problema de investigación

A pesar de la creciente disponibilidad de información relacionada con el comportamiento laboral de los colaboradores, muchas organizaciones aún carecen de herramientas capaces de transformar estos datos en indicadores preventivos de riesgo psicosocial.

El fenómeno del burnout laboral se ha consolidado en la última década como uno de los desafíos más críticos para la salud ocupacional y la gestión de recursos humanos a nivel global (Salvagioni et al., 2017; Maslach & Leiter, 2016). Definido como un fenómeno multidimensional de agotamiento físico, emocional y mental, este síndrome emerge en contextos caracterizados por alta exigencia, sobrecarga sostenida de tareas y condiciones laborales desfavorables. El burnout laboral representa actualmente uno de los principales retos dentro de la salud ocupacional.

El Trabajo Final de Máster se sitúa en la intersección entre la psicología organizacional y la ciencia de datos, con un enfoque centrado en el análisis del burnout y a la evaluación de modelos de Machine Learning para apoyar su detección temprana mediante variables laborales.

A pesar de la creciente disponibilidad de datos laborales y psicométricos, numerosas organizaciones carecen de mecanismos analíticos capaces de identificar patrones asociados al agotamiento profesional. En muchas organizaciones, las estrategias relacionadas con burnout continúan aplicándose de forma reactiva (Boudreau & Cascio, 2017).

Adicionalmente, existe una fragmentación significativa entre las fuentes de información organizacional. Los datos operativos, sociodemográficos y psicométricos suelen encontrarse aislados, lo que dificulta la construcción de modelos integrales que expliquen la relación entre carga laboral y bienestar psicológico.

Prieto (2013) señala que las organizaciones deben identificar estratégicamente a sus recursos humanos más destacados para desarrollar estrategias que aseguren su estabilidad laboral, lo que requiere un uso consciente y proactivo de la información asociada al talento.

En este contexto, se formula la siguiente pregunta de investigación:

¿De qué manera la integración de Business Intelligence y modelos supervisados de Machine Learning puede facilitar la detección temprana del riesgo de burnout laboral mediante el análisis de variables sociodemográficas, laborales y psicométricas de veterinarios en Alemania?

Hipótesis

Hipótesis general

Las variables psicométricas y laborales de los ítems ERI 1-10 y psicométricas de las variables CBI 1-6 facilitan predecir significativamente el riesgo alto de burnout laboral mediante modelos supervisados de Machine Learning.

Hipótesis específicas

- Existe una relación significativa entre jornadas laborales extensas y niveles elevados de burnout.
- El desequilibrio esfuerzo-recompensa incrementa la probabilidad de agotamiento profesional.
- Los modelos supervisados están orientados a clasificar el riesgo de burnout con métricas de desempeño estadísticamente aceptables.

- Las variables demográficas influyen en la prevalencia del burnout dentro del gremio veterinario alemán.

Objetivos de Investigación

Objetivo general

Desarrollar BurnoutGuard como sistema analítico para la detección temprana del riesgo de burnout laboral mediante la integración de Business Intelligence, análisis exploratorio de datos y modelos supervisados de Machine Learning.

Objetivos específicos

1. Seleccionar y depurar datasets relacionados con burnout laboral y variables psicométricas.
2. Analizar variables sociodemográficas, laborales, variables (ERI 1 al 10) y psicológicas (variables CBI 1 al 6) asociadas al agotamiento profesional.
3. Desarrollar dashboards interactivos mediante Tableau Desktop para una visualización estratégica.
4. Implementar modelos supervisados de Machine Learning para clasificación de riesgo.
5. Evaluar el desempeño predictivo de los modelos mediante métricas de clasificación.
6. Identificar variables relevantes para la predicción del riesgo de burnout.
7. Proponer una arquitectura empresarial escalable para futuras implementaciones organizacionales.

Metodología

Las principales fases metodológicas comprenden:

- Recolección y depuración de datos.
- Transformación y normalización de variables.
- Análisis exploratorio de datos (EDA).

- Modelado relacional.
- Visualización interactiva en Tableau Desktop.
- Desarrollo de modelos supervisados de Machine Learning.
- Evaluación comparativa mediante métricas de clasificación.

Marco Teórico

Conceptualización del Síndrome de Burnout

El burnout debe analizarse como un síndrome multidimensional asociado al entorno laboral.

El modelo de burnout propuesto por Maslach y Jackson (1981) describe este fenómeno a partir de tres dimensiones fundamentales: agotamiento emocional, despersonalización y baja realización personal. El agotamiento emocional se refiere al desgaste físico y psicológico derivado de una exposición prolongada a situaciones de estrés laboral; la despersonalización implica el desarrollo de actitudes distantes o negativas hacia otras personas en el entorno de trabajo; mientras que la baja realización personal se manifiesta mediante una percepción negativa sobre el desempeño profesional y los logros alcanzados.

La combinación de estas dimensiones permite comprender el burnout como un fenómeno complejo que afecta tanto al bienestar de los trabajadores como a la productividad organizacional. Por ello, este modelo constituye una de las principales referencias teóricas para el estudio de los riesgos psicosociales y la identificación temprana de factores asociados al agotamiento laboral (Maslach et al., 2001).

El Burnout en la Profesión Veterinaria: Los veterinarios llegan a vivir situaciones de alto estrés emocional al tener que lidiar con duras situaciones involucrando a criaturas vivas, clientes difíciles y largas jornadas de trabajo. Al trabajar con seres vivos los veterinarios llegan a ver accidentes, practicar eutanasia y situaciones de abuso animal.

Modelos de Estrés Laboral y Riesgo Psicosocial

Modelo de Desequilibrio Esfuerzo-Recompensa (ERI): Propone que el estrés surge cuando el alto esfuerzo realizado por el trabajador no se corresponde con una recompensa adecuada en términos de salario, reconocimiento profesional o estabilidad laboral. Esta situación genera un desequilibrio que incrementa el riesgo de deterioro físico y psicológico (Siegrist, 1996).

Maslach y Jackson (1981) definen el burnout como un síndrome compuesto por agotamiento emocional, despersonalización y baja realización personal. Esta definición continúa siendo una de las referencias más utilizadas en la literatura científica debido a su capacidad para explicar el fenómeno desde una perspectiva multidimensional.

Diversos estudios señalan, la diferencia conceptual entre el análisis teórico del burnout y su manifestación progresiva en contextos laborales reales. Diversos estudios en psicología organizacional evidencian que profesionales altamente competentes tienden a normalizar las primeras señales del agotamiento, interpretándolas como episodios temporales, lo que retrasa la identificación del síndrome (Leiter & Maslach, 2016).

Diferencia entre estrés laboral y burnout

Aunque ambos conceptos suelen utilizarse indistintamente en el lenguaje cotidiano, el estrés laboral y el burnout son considerados como fenómenos distintos que requieren abordajes diferenciados. La confusión entre ambos puede retrasar procesos de recuperación e intervención.

	Estrés laboral	Burnout laboral
Duración	Temporal, ligado a un proyecto o período	Crónico, persiste semanas o meses
Emoción predominante	Ansiedad, hiperactivación	Vacío, desconexión emocional

	Estrés laboral	Burnout laboral
Nivel de energía	Exceso de activación (nerviosismo)	Agotamiento total, sin reservas
Motivación	Presente pero desbordada	Ausente o cinismo activo
Recuperación	Descanso + eliminar el estresor	Requiere intervención profunda y tiempo
Impacto laboral	Rendimiento fluctuante	Desvinculación o abandono profesional
Relación con otros	Irritabilidad puntual	Despersonalización: tratar a compañeros y clientes como objetos
Reconocimiento OMS	Factor de riesgo psicosocial	Fenómeno ocupacional asociado al estrés laboral crónico que no ha sido gestionado adecuadamente (World Health Organization, 2019).

Tabla 1 – Comparación entre estrés laboral y Burnout

La aparición sostenida de indicadores como agotamiento emocional, cinismo o disminución de la realización profesional puede interpretarse como una manifestación progresiva del síndrome de burnout, particularmente cuando dichas señales persisten durante periodos prolongados de exposición a factores estresantes laborales (Maslach & Leiter, 2016).

Estrategias de prevención

La prevención del burnout requiere la implementación de estrategias organizacionales orientadas al establecimiento de límites laborales saludables. Diversos autores indican la importancia de intervenciones organizacionales que promuevan el equilibrio entre demandas laborales y recursos disponibles, así como una cultura que favorezca el bienestar psicológico de los trabajadores (Maslach & Leiter, 2016).

La literatura sobre bienestar ocupacional sugiere que la capacidad para establecer límites laborales saludables se relaciona con factores individuales y organizacionales, entre ellos la definición clara de prioridades profesionales, las competencias de comunicación interpersonal y la existencia de una cultura organizacional que favorezca prácticas de autocuidado y equilibrio laboral (Leiter & Maslach, 2016; Bakker & Demerouti, 2007).

Diversos estudios sobre gestión del tiempo y bienestar laboral destacan que la priorización de tareas, la planificación estructurada de actividades y la asignación de periodos específicos para recuperación física y mental contribuyen a reducir la percepción de sobrecarga y favorecen una mejor administración de los recursos personales (Claessens et al., 2007).

Las investigaciones actuales sobre bienestar ocupacional sugieren que la prevención del burnout requiere considerar no solo indicadores de productividad, sino también factores relacionados con la recuperación psicológica, el equilibrio entre demandas y recursos laborales y la adecuación entre las capacidades del trabajador y las exigencias de su puesto (Bakker & Demerouti, 2007; Maslach & Leiter, 2016).

Gestión del tiempo y energía

Aunque las estrategias tradicionales de administración del tiempo contribuyen a mejorar la organización del trabajo, diversos autores señalan que la prevención del agotamiento laboral también depende de la adecuada gestión de recursos psicológicos y emocionales, así como de mecanismos de recuperación que permitan afrontar las demandas del entorno laboral (Claessens et al., 2007; Maslach et al., 2001)

La evidencia disponible indica que una adecuada gestión del tiempo, la planificación estructurada de tareas y la priorización efectiva de actividades contribuyen a reducir la sobrecarga laboral y mejorar el bienestar psicológico (Claessens et al., 2007). La realización prolongada de actividades con elevada carga emocional y escaso control percibido puede incrementar el riesgo de agotamiento laboral (Maslach et al., 2001).

Business Intelligence y Big Data

El uso de Business Intelligence y Big Data en contextos organizacionales permite gestionar grandes volúmenes de datos caracterizados por su volumen, velocidad y variedad, características que exceden las capacidades de los métodos tradicionales de análisis (Laney, 2001). Estas tecnologías facilitan la

transformación de datos en conocimiento útil para apoyar la toma de decisiones estratégicas y operativas (Sharda et al., 2023).

Alcance y limitaciones

El alcance del estudio se centra en el desarrollo de un sistema analítico dirigido a la detección temprana del riesgo de burnout utilizando técnicas de Business Intelligence y Machine Learning.

El proyecto no pretende sustituir evaluaciones clínicas ni diagnósticos psicológicos profesionales. Los resultados obtenidos deben interpretarse como mecanismos de apoyo para la toma de decisiones preventivas dentro de contextos organizacionales.

Entre las principales limitaciones destacan:

- Dependencia de datasets secundarios.
- Restricciones asociadas al contexto específico del gremio veterinario alemán.
- Posibles sesgos derivados de autopercepción en instrumentos psicométricos.
- Limitaciones de generalización hacia otros sectores laborales.

3. ESTADO DE LA CUESTIÓN

Conceptualización del síndrome de burnout

El síndrome de burnout es un fenómeno ocupacional asociado al estrés laboral crónico no gestionado adecuadamente. Maslach y Jackson (1981) lo definieron como un síndrome psicológico compuesto por agotamiento emocional, despersonalización y disminución de la realización personal.

La Organización Mundial de la Salud incorporó el burnout dentro de la Clasificación Internacional de Enfermedades (CIE-11), consolidando su reconocimiento como un fenómeno ocupacional relevante dentro de la salud organizacional.

Modelos teóricos del estrés laboral

El modelo Job Demands-Resources (JD-R), propuesto por Bakker y Demerouti (2007), establece que el burnout surge cuando las demandas laborales exceden los recursos disponibles para afrontarlas.

El modelo Effort-Reward Imbalance (ERI), desarrollado por Siegrist (1996), plantea que el estrés laboral crónico surge cuando el esfuerzo realizado por el trabajador no recibe una recompensa proporcional.

Copenhagen Burnout Inventory

El Copenhagen Burnout Inventory (CBI) significa uno de los instrumentos psicométricos más utilizados para medir agotamiento profesional. Fue desarrollado por Kristensen et al. (2005) como una alternativa centrada en la fatiga física y psicológica asociada al trabajo.

El instrumento evalúa tres dimensiones principales:

- Burnout personal.
- Burnout relacionado con el trabajo.

- Burnout relacionado con clientes o usuarios.

La utilización del CBI sugiere cuantificar niveles de agotamiento mediante escalas estandarizadas, facilitando procesos de análisis comparativo y modelado predictivo.

Burnout en la profesión veterinaria

La profesión de enfermería y medicina veterinaria enfrenta el agotamiento como un problema creciente que afecta directamente el bienestar del personal, la retención de talento y, en consecuencia, la calidad del servicio clínico y el bienestar animal. Si bien las estrategias de autocuidado pueden mitigar estos efectos a corto plazo, se requieren intervenciones estructurales y organizativas para lograr un cambio sostenible en el tiempo.

Investigaciones recientes enfocadas en el análisis de las Áreas de Vida Laboral y la salud ocupacional del gremio han identificado que el síndrome de burnout en este personal se encuentra directamente vinculado a fallas multidimensionales dentro del entorno de trabajo (Chapman et al., 2024; Delgado Carabayo et al., 2025). De acuerdo con estas evidencias, los principales factores de riesgo organizativos y estresores críticos son:

- **Alta carga de trabajo:** Jornadas laborales extensas y picos de presión operativa.
- **Bajo control y autonomía:** Limitada participación en la toma de decisiones clínicas o administrativas.
- **Deficiencias estructurales:** Baja remuneración económica e infrautilización de las capacidades del personal.
- **Clima organizacional adverso:** Incivilidad entre compañeros de equipo y percepción de trato desigual.
- **Desbalance personal:** Mal equilibrio entre la vida laboral y la vida familiar por sobrecarga de turnos.
- **Impacto emocional intrínseco:** Exposición constante al sufrimiento animal, manejo del duelo de los clientes, dilemas éticos y la práctica de la eutanasia.

Business Intelligence y People Analytics

Desde una perspectiva organizacional, Business Intelligence permite transformar grandes volúmenes de datos en información útil para la toma de decisiones. Su aplicación en recursos humanos ha dado origen al enfoque conocido como People Analytics, orientado al análisis sistemático del comportamiento laboral.

Dentro del contexto organizacional, las plataformas de BI permiten integrar múltiples fuentes de información para identificar patrones operativos relevantes. Tableau Desktop constituye una de las herramientas más utilizadas para análisis visual interactivo debido a sus capacidades de segmentación dinámica y exploración multidimensional.

Machine Learning aplicado a salud organizacional

Los modelos de Machine Learning ofrecen la posibilidad de identificar patrones complejos que difícilmente podrían detectarse mediante técnicas estadísticas tradicionales. Esta capacidad resulta especialmente relevante cuando se analizan fenómenos multifactoriales como el burnout.

En contextos organizacionales, los modelos supervisados permiten clasificar y predecir fenómenos asociados al comportamiento humano, desempeño laboral y riesgos psicosociales.

Entre los algoritmos más utilizados para clasificación destacan:

- Regresión logística.
- Random Forest.
- Árboles de decisión.
- Support Vector Machine (SVM).
- Gradient Boosting.

Visualización de datos organizacionales

La visualización de datos es el proceso de transformar los datos en representaciones visuales que pueden ayudarle a explorar, analizar y comunicar información. La visualización de datos puede ayudarle a dar sentido a conjuntos de datos grandes y diversos, revelar patrones y tendencias, resaltar valores atípicos y anomalías, y comparar diferentes escenarios.

El agotamiento puede tener muchas causas, como la carga de trabajo, los plazos, las expectativas, las relaciones, la cultura, los valores y los factores personales. Sin embargo, estas causas no siempre son fáciles de identificar, medir o monitorear. La visualización de datos puede ayudarlo a recopilar y mostrar datos relevantes sobre su trabajo y su vida, como horas, tareas, objetivos, comentarios, satisfacción, estrés, estado de ánimo, energía, sueño, salud, pasatiempos e interacciones sociales.

Actuar sobre tus datos para el agotamiento es el paso más importante y desafiante, ya que requiere que tomes decisiones y tomes medidas para mejorar tu situación. Puede utilizar sus visualizaciones de datos para identificar y priorizar las áreas en las que necesita realizar cambios, tales como: reducir o delegar su carga de trabajo, establecer o renegociar sus plazos, aclarar o ajustar sus expectativas, mejorar o cambiar sus relaciones, alinear o redefinir sus valores y mejorar o diversificar sus factores personales. También puede utilizar sus visualizaciones de datos para supervisar y evaluar el impacto de sus acciones, y para celebrar y compartir sus logros. (LinkedIn, 2023).

4. DESARROLLO METODOLÓGICO

Diseño de investigación

La investigación utiliza un enfoque cuantitativo no experimental con alcance descriptivo, exploratorio y predictivo.

El notebook correspondiente al EDA fue desarrollado utilizando Python como lenguaje principal de programación. La estructura implementada busca simplificar la validación, transformación, resumen y visualización de datos tabulares sin incorporar complejidad arquitectónica innecesaria.

Dataset principal y datasets complementarios

El dataset principal utilizado en esta investigación procede de un estudio sobre factores psicosociales, burnout, depresión e ideación suicida en profesionales veterinarios de Alemania, publicado por Schwerdtfeger et al. (2024). El conjunto de datos original estaba compuesto por 3181 registros obtenidos mediante encuestas aplicadas a profesionales del sector veterinario alemán.

Durante la fase de preparación de datos se realizaron procesos de validación, depuración y transformación orientados a garantizar la calidad y consistencia de la información. Como resultado, se eliminaron registros con valores inválidos, inconsistencias y datos incompletos, obteniéndose un conjunto final de 3053 registros válidos para el análisis exploratorio, la construcción de dashboards y el entrenamiento de modelos predictivos.

El dataset final incorpora variables psicométricas asociadas al Inventario de Burnout de Copenhague (CBI), variables relacionadas con el modelo Desequilibrio Esfuerzo-Recompensa (ERI), así como variables demográficas y laborales de los participantes.

La descripción del dataset contempla los siguientes elementos:

- Origen del dataset.

- Cantidad de registros.
- Variables incluidas.
- Contexto ocupacional del gremio veterinario alemán.
- Variable objetivo *Burnout_Score*.

Las variables correspondientes al ERI y CBI fueron obtenidas del dataset original utilizado en la investigación. Las escalas de respuesta y la codificación de los valores siguen la estructura definida en la fuente de datos original (European Bioinformatics Institute [EMBL-EBI], 2024).

Para las variables ERI se utiliza una escala ordinal de 1 a 4, donde cada valor representa:

Valor	Interpretación
1	Totalmente en desacuerdo
2	En desacuerdo
3	De acuerdo
4	Totalmente de acuerdo

Tabla 2 - Etiquetas y valores ERI. Fuente. Adaptado de EMBL-EBI (2024).

Para las variables CBI se utiliza una escala de 1 a 5 asociada a etiquetas y valores estandarizados:

Escala original	Etiqueta	Escala ajustada
1	Siempre	100
2	A menudo	75
3	A veces	50
4	Rara vez	25
5	Nunca	0

Tabla 3 - Etiquetas y valores CBI. Fuente. Adaptado de EMBL-EBI (2024).

Los datasets complementarios se utilizan exclusivamente para contraste conceptual y apoyo metodológico.

La variable objetivo *Burnout_Score* se construirá a partir de las variables CBI_01 a CBI_06. En primer lugar, las respuestas del cuestionario CBI serán transformadas a una escala estandarizada de 0 a 100 puntos. Posteriormente, se calculará el promedio de las puntuaciones obtenidas en los seis ítems para generar el indicador CBI_SCORE de cada individuo.

Finalmente, se definirá la variable binaria *Burnout_Score* utilizando una puntuación igual o superior a 50 como punto de corte de CBI_SCORE. Los individuos con una puntuación igual o superior a dicho umbral serán clasificados

como casos de burnout (valor = 1), mientras que aquellos con puntuaciones inferiores serán clasificados como no burnout (valor = 0).

Flujo de datos



Figura 1 - Flujo de datos. Fuente: elaboración propia.

El modelo de flujo de datos propuesto se estructura alrededor de un proceso periódico de recopilación, transformación, almacenamiento y análisis de información organizacional relacionada con el riesgo de burnout laboral.

La fuente principal de datos para las variables ERI y CBI es propio de encuestas periódicas aplicadas a los colaboradores con el objetivo de evaluar indicadores asociados al estado emocional, percepción del entorno laboral y niveles de agotamiento profesional.

Estas encuestas son la base para recopilar información psicométrica relacionada con:

- Desequilibrio esfuerzo-recompensa.
- Agotamiento emocional.
- Fatiga laboral.
- Percepción de reconocimiento organizacional.
- Estrés asociado al trabajo.

Posteriormente, los datos recolectados son integrados con información complementaria proveniente de sistemas organizacionales como HRIS/ERP, registros de jornada laboral, métricas de ausentismo y variables sociodemográficas.

El flujo de procesamiento propuesto contempla las siguientes etapas:

- Ingesta de datos: Recolección de encuestas y extracción de información desde sistemas corporativos mediante procesos batch.
- Almacenamiento inicial: Persistencia de datos originales dentro de Azure Data Lake Storage Gen2 para mantener trazabilidad y auditoría.
- Transformación y limpieza: Validación, normalización y depuración de datos utilizando Azure DataBricks y procesos ETL/ELT.
- Capa analítica: Construcción de datasets curados y estructurados para análisis organizacional y consumo analítico.
- Modelado predictivo: Ejecución de modelos supervisados de Machine Learning para clasificación de riesgo de burnout.
- Visualización y consumo: Publicación de resultados mediante dashboards interactivos en Tableau orientados a Recursos Humanos y liderazgo organizacional.
- Inferencia y monitoreo: Generación periódica de predicciones y monitoreo continuo de desempeño del modelo y calidad de datos.

El flujo propuesto busca garantizar trazabilidad, escalabilidad y capacidad de integración con entornos empresariales reales, permitiendo evolucionar desde un análisis descriptivo hacia un modelo preventivo basado en analítica organizacional y Machine Learning.

Preparación y transformación de datos

Análisis Exploratorio de Datos

El EDA se ajusta a la revisión estructurada inicial de un conjunto de datos previa al modelado predictivo. Su propósito consiste en comprender la estructura, calidad, distribuciones, relaciones y limitaciones de los datos.

El EDA corresponde a una etapa previa al modelado predictivo, es un proceso de recopilación de evidencia que permite determinar si el modelado resulta metodológicamente viable y qué decisiones de preprocesamiento deben aplicarse.

Dentro del notebook desarrollado, el EDA busca responder las siguientes preguntas operativas:

- ¿El conjunto de datos carga correctamente?
- ¿Qué columnas existen y qué tipos de datos identifica pandas?
- ¿Existen valores faltantes o valores centinela inválidos?
- ¿Cuál es el nivel de desbalance de la variable Burnout_Score?
- ¿Qué variables son numéricas, categóricas codificadas o potencialmente susceptibles a fuga de información?
- ¿Qué patrones visuales pueden apoyar etapas posteriores del análisis?

Se realiza inicialmente una inspección visual mediante Microsoft Excel. Posteriormente, se agregan tres columnas auxiliares orientadas a documentar la cadena de transformaciones aplicadas al dataset. Las transformaciones fueron separadas en distintas columnas para favorecer la trazabilidad del proceso.

Columnas auxiliares agregadas

- Columna TRANSLATE: Mediante la función TRANSLATE, se procesa la columna working hours con el objetivo de traducir respuestas textuales en alemán relacionadas con la cantidad de horas trabajadas. Cuando el valor se ajusta a un dato numérico, no se realiza ninguna transformación adicional mediante una sentencia condicional IF.
- Columna CONVERT: Utilizando la función VALUE, los valores textuales son transformados a formato numérico entero. Si el contenido ya es numérico, no se aplica ninguna conversión adicional.
- Columna REDONDEAR: Una vez obtenidos valores numéricos consistentes para la variable working hours, los valores flotantes son redondeados al entero más cercano.

Adicionalmente, se eliminan columnas que no resultan relevantes para los objetivos del Trabajo Final de Máster.

Paso	Sección del Notebook	Propósito
1	Setup - Importar librerías	Importar bibliotecas necesarias como pandas, numpy, matplotlib, seaborn, os y json. También se configura el estilo visual de los gráficos para mantener consistencia visual.
2	Configuración	Definir rutas de entrada y salida, reportes, modelos, variable objetivo (Burnout_Score) y listas de columnas categóricas, ERI y CBI.
3	Mapeo de valores	Crear el diccionario valores_cbi para transformar los valores originales del cuestionario CBI a una escala estandarizada de 0 a 100.
4	Cargar los datos	Importar el dataset desde el archivo CSV germany.veterinarians.csv hacia un DataFrame de pandas y validar la carga inicial.
5	Limpieza y transformación de datos	Convertir tipos de datos, reemplazar valores inválidos por np.nan, eliminar columnas irrelevantes y renombrar variables para mejorar claridad y consistencia.
6	Eliminar valores faltantes	Generar el DataFrame limpio df_clean eliminando filas con valores faltantes después de la limpieza inicial
7	Variable objetivo	Construir la variable objetivo Burnout_Score mediante el cálculo del promedio CBI_SCORE y la clasificación binaria utilizando 50 puntos como umbral de burnout.

Tabla 4 – Pasos del proceso EDA. Fuente: elaboración propia.

Herramientas tecnológicas

Las principales herramientas utilizadas fueron:

Tecnología / Componente	Uso en el Proyecto	Categoría
 Python <i>Figura 2- Logo Python</i>	Lenguaje principal utilizado para ejecutar el flujo EDA, estructurar la lógica del notebook y coordinar la generación de archivos.	Gestionar el procesamiento y análisis de datos.
 Jupyter Notebook <i>Figura 3 - Logo Jupyter</i>	Ambiente interactivo utilizado para integrar documentación, código, tablas, gráficos y validaciones.	Ejecución y documentación
Pandas	Biblioteca utilizada para lectura de archivos CSV, manipulación tabular, generación de resúmenes y exportación de reportes.	Manipulación de datos


Tecnología / Componente	Uso en el Proyecto	Categoría
 Figura 4 - Logo Pandas		
NumPy  Figura 5 - Logo NumPy	Biblioteca orientada al manejo de valores faltantes y operaciones numéricas.	Cómputo numérico
Matplotlib  Figura 6 - Logo Matplotlib	Biblioteca base utilizada para generación y almacenamiento de visualizaciones.	Visualización
Seaborn  Figura 7 - Logo seaborn	Biblioteca orientada a visualización estadística avanzada y mejora de legibilidad gráfica.	Visualización
scikit-learn / sklearn  Figura 8 - Logo sklearn	Biblioteca utilizada en las etapas posteriores del proyecto para modelos supervisados y clustering.	Aprendizaje automático

Tabla 5 - librerías utilizadas. Fuente: elaboración propia.

Desarrollo de dashboards en Tableau



Figura 9 - Logo Tableau

Los dashboards desarrollados demuestran:

- Segmentación dinámica.
- Análisis geográfico.
- Análisis demográfico.
- Exploración multidimensional.
- Monitoreo de indicadores asociados al burnout.

Modelos de Machine Learning

Dado que la variable objetivo corresponde a una clasificación binaria derivada del umbral de 50 puntos del “CBI_SCORE” y considerando que el conjunto de datos presenta las siguientes características:

- Tipos de datos mixtos (categóricos y numéricos)
- Dimensionalidad moderada
- Relaciones no lineales entre variables
- Posibles efectos de interacción

Se seleccionaron tres algoritmos supervisados considerados apropiados para problemas de clasificación binaria con estas propiedades:

- Regresión logística.
- Random Forest.
- Support Vector Machine (SVM).

Variables utilizadas en el modelo completo

La configuración final del modelo incorpora variables provenientes de tres dimensiones principales: factores psicométricos, variables laborales y características sociodemográficas. Para el entrenamiento se utilizaron los ítems *ERI_1 a ERI_10*, los ítems *CBI_01 a CBI_06* y las variables *age*, *age_group*, *working_hours*, *gender*, *status_of_employment*, *field_of_work*, *community_size* e *income*.

La variable objetivo *Burnout_Score* fue construida a partir de las puntuaciones obtenidas en los ítems *CBI_01 a CBI_06*. En consecuencia, existe una relación

directa entre parte de las variables predictoras y la variable objetivo utilizada durante el entrenamiento. La inclusión de estas variables como predictores contribuye significativamente al desempeño del modelo en la identificación de individuos con niveles elevados de burnout, al emplear los mismos indicadores psicométricos utilizados para definir el fenómeno analizado.

Respecto al riesgo de data leakage, las variables CBI forman parte de la información disponible en el conjunto de datos y constituyen indicadores psicométricos válidos para la medición del burnout. Por tanto, su utilización no implica la incorporación de información futura ni de variables externas al escenario de predicción considerado. Sin embargo, esta dependencia debe tenerse en cuenta al interpretar los resultados obtenidos.

El elevado desempeño alcanzado por el modelo refleja, en gran medida, su capacidad para identificar patrones presentes en los indicadores CBI utilizados para construir la variable objetivo. Por ello, los resultados deben interpretarse principalmente como una capacidad de clasificación del riesgo de burnout basada en información psicométrica estrechamente relacionada con la definición del fenómeno evaluado, y no como una capacidad predictiva sustentada exclusivamente en variables laborales o sociodemográficas independientes.

División de datos y preprocesamiento dentro del pipeline

Los datos fueron divididos en conjuntos de entrenamiento, validación y prueba mediante una partición estratificada, con el objetivo de preservar la proporción de clases de la variable objetivo en cada subconjunto. El conjunto de entrenamiento se empleó para el ajuste de los modelos, el conjunto de validación para la optimización de hiperparámetros y la selección del umbral de clasificación, y el conjunto de prueba para la evaluación final del desempeño predictivo.

El preprocesamiento de los datos se implementó mediante las clases Pipeline y ColumnTransformer de Scikit-learn, garantizando que todas las transformaciones fueran ejecutadas exclusivamente sobre los datos de entrenamiento y posteriormente aplicadas de forma consistente a los conjuntos

de validación y prueba. Este enfoque contribuye a minimizar el riesgo de data leakage y favorece la reproducibilidad del proceso de modelado.

Las variables numéricas fueron imputadas utilizando la mediana como medida de tendencia central, mientras que las variables categóricas fueron imputadas mediante la moda. Posteriormente, las variables categóricas fueron transformadas mediante la técnica One-Hot Encoding para su utilización en los algoritmos de aprendizaje supervisado.

Adicionalmente, en los modelos de Regresión Logística y Support Vector Machine (SVM) se aplicó un proceso de estandarización mediante StandardScaler, debido a que estos algoritmos son sensibles a las diferencias de escala entre las variables predictoras. Esta transformación no fue necesaria para el modelo Random Forest, dado que los árboles de decisión son inherentemente robustos frente a variaciones en la escala de los datos.

Entrenamiento y optimización de modelos

Se evaluaron tres algoritmos de clasificación supervisada: Random Forest, Regresión Logística y SVM. La optimización de hiperparámetros se realizó mediante GridSearchCV, utilizando validación cruzada estratificada con el propósito de preservar la distribución de clases durante el proceso de entrenamiento y validación.

La métrica principal empleada para la selección de hiperparámetros fue la balanced accuracy, debido a su capacidad para evaluar el desempeño de manera equilibrada entre las clases positiva y negativa. Esta métrica resulta especialmente apropiada en problemas donde existe desbalance entre categorías, ya que considera de forma equivalente la capacidad del modelo para identificar correctamente ambas clases.

Una vez identificada la configuración óptima de hiperparámetros para cada algoritmo, se llevó a cabo un proceso adicional de optimización del umbral de clasificación utilizando el conjunto de validación. En lugar de adoptar el valor

convencional de 0.50 como punto de corte, se evaluaron múltiples umbrales sobre las probabilidades estimadas por cada modelo, seleccionándose aquel que maximizó la métrica balanced accuracy.

Finalmente, los modelos optimizados fueron evaluados sobre el conjunto de prueba utilizando los hiperparámetros y umbrales previamente seleccionados. Este procedimiento permitió obtener una estimación más realista del desempeño esperado en escenarios de aplicación práctica, reduciendo el riesgo de sesgo asociado a la selección arbitraria de umbrales de decisión.

Evaluación del desempeño e importancia de variables

El desempeño de los modelos se evaluó mediante las métricas accuracy, balanced accuracy, precisión (precision), exhaustividad (recall) y puntuación F1 (F1-score) para ambas clases de la variable objetivo. La métrica principal utilizada para la comparación entre modelos fue la balanced accuracy, debido a su capacidad para proporcionar una evaluación equilibrada del desempeño cuando existe desbalance entre clases.

La utilización de esta métrica permite valorar de manera conjunta la capacidad del modelo para identificar correctamente tanto los casos clasificados como riesgo de burnout como aquellos clasificados como ausencia de riesgo, evitando interpretaciones sesgadas derivadas de la predominancia de una clase sobre la otra.

Adicionalmente, se calculó la importancia por permutación (Permutation Feature Importance) con el objetivo de analizar la contribución individual de cada variable al desempeño predictivo del modelo. Este procedimiento consiste en desordenar aleatoriamente los valores de una variable en el conjunto de prueba y medir la variación producida en la métrica de evaluación seleccionada. Una disminución significativa de la balanced accuracy tras la permutación indica que la variable aporta información relevante para el proceso de clasificación.

En el modelo desarrollado, el análisis de importancia por permutación permitió identificar las variables con mayor influencia sobre la clasificación del riesgo alto de burnout, considerando conjuntamente los factores psicométricos del modelo ERI, los indicadores del cuestionario CBI y las variables demográficas y laborales incluidas en el conjunto de datos.

5. ANÁLISIS Y RESULTADOS

Análisis Univariante del EDA

Inicialmente, se analizó la distribución individual de cada variable numérica con el propósito de comprender su rango, tendencia central y dispersión. Para ello, se generaron histogramas que representan la frecuencia de los valores dentro de intervalos específicos para cada característica.




Figura 10 - Análisis Univariante. Fuente: elaboración propia.

Distribuciones de las variables ERI (Desequilibrio Esfuerzo-Recompensa):

Estas características tienen rangos de 1 a 4. La mayoría de las distribuciones muestran una ligera asimetría negativa o picos en valores más altos, sugiriendo que los veterinarios tienden a reportar puntajes más bajos en factores de esfuerzo.

Las variables ERI están diseñadas para medir diferentes aspectos del esfuerzo. Un sesgo hacia puntuaciones bajas podría indicar que los encuestados perciben un nivel de esfuerzo moderado o bajo, o que hay una tendencia a subreportar altos niveles de esfuerzo.

Entender la distribución de estas variables es crucial para comprender los factores de esfuerzo. Los picos en valores bajos pueden ser informativos sobre la percepción general de la muestra.

Si hay un sesgo significativo en la respuesta, podría afectar la capacidad del modelo para capturar la verdadera relación entre el esfuerzo y el burnout.

Distribuciones de CBI: Estas características, después de la transformación a puntaje, tienen un rango de 0 a 100. Muchas de estas distribuciones muestran asimetría positiva o picos en valores más bajos.

Las variables CBI, que miden aspectos del burnout, al presentar picos en valores bajos (menos burnout) después de la transformación a puntaje, sugieren que una parte de la población no experimenta niveles elevados de burnout o que su percepción es baja.

La distribución de estas variables es fundamental para entender la manifestación del burnout en la población. La tendencia hacia valores bajos es un buen punto de partida para identificar factores protectores o de riesgo.

Una asimetría muy pronunciada podría dificultar la identificación de subgrupos con altos niveles de burnout si el modelo no está diseñado para manejar distribuciones no normales.

Edad y Horas de Trabajo: Ambas variables presentan una distribución más cercana a la normal, con una ligera asimetría.

La edad y las horas de trabajo son factores demográficos y laborales importantes que pueden influir en el burnout.

Estas distribuciones normales o ligeramente asimétricas son adecuadas para la mayoría de los modelos predictivos y permiten una interpretación más directa de su impacto.

Si hay valores atípicos extremos, podrían sesgar el análisis y el modelado si no se tratan adecuadamente.

Balance de la Variable Objetivo




Figura 11 - Distribución de la variable objetivo. Fuente: elaboración propia.

Ligeramente desbalanceada (53.39% 'Burnout').

Indica que la población de veterinarios estudiada tiene una proporción significativa de individuos en estado de 'burnout', lo cual es relevante dado el contexto de salud ocupacional.

Es un problema común en la profesión veterinaria y este dataset lo refleja. El leve desbalance debe ser considerado en el modelado para evitar sesgos (e.g., usando métricas como F1-score o accuracy) y quizás técnicas de muestreo.

Modelos ingenuos podrían favorecer la clase mayoritaria.

Valores Faltantes e Inválidos

Mediante el uso de la biblioteca Pandas se identificó la ausencia de valores faltantes estándar dentro del archivo CSV original. No obstante, durante el

proceso de validación se detectaron 14 registros donde la variable birth year presentaba el valor inválido.

Debido a que dicho valor no representa un año de nacimiento válido, estos registros fueron excluidos del análisis para preservar la consistencia y calidad del dataset.

Análisis Bivariante del EDA

Posteriormente, se analizaron las relaciones existentes entre variables y su asociación con la variable objetivo "Burnout_Score". Este análisis permitió identificar posibles predictores del burnout y comprender con mayor profundidad los factores relacionados con el agotamiento profesional.

Mapa de Calor de Correlación

Se generó un mapa de calor de correlación para las variables numéricas del dataset. Esta representación visual es la base para identificar la intensidad y dirección de las relaciones lineales entre pares de variables.

Los coeficientes cercanos a "1" indican correlaciones positivas fuertes, mientras que valores cercanos a "-1" representan correlaciones negativas fuertes. Por el contrario, valores próximos a cero indican relaciones lineales débiles o inexistentes.




Figura 12 - Mapa de Calor de correlación. Fuente: elaboración propia.

Se observa una multicolinealidad esperada entre las variables CBI (entre sí) y ERI (entre sí), ya que miden constructos relacionados y componentes de los mismos índices. Esto es común en cuestionarios con múltiples ítems que evalúan una misma dimensión. Será importante considerar estas relaciones en fases de modelado para evitar la redundancia de información.

Otras relaciones entre variables numéricas son generalmente débiles, indicando que la mayoría de las características numéricas no están fuertemente correlacionadas entre sí, salvo las agrupaciones CBI y ERI.




Figura 13 - Boxplots variables CBI. Fuente: Elaboración propia.

Columnas CBI: Como era de esperar, dada la construcción del Burnout_Score a partir del CBI_SCORE, todas las columnas CBI muestran correlaciones muy fuertes y positivas con el Burnout_Score. Esto es fundamental, ya que el Burnout_Score se deriva directamente de la escala CBI.

Los boxplots para las variables CBI exhiben diferencias muy marcadas y consistentemente claras entre los grupos Burnout_Score negativo y Burnout_Score positivo. El grupo con Burnout_Score positivo presenta distribuciones con medianas significativamente más altas y rangos intercuartílicos desplazados hacia valores máximos en todas las variables CBI, lo que visualmente demuestra que niveles más altos en estas variables están directamente asociados con la clasificación de burnout. La superposición entre las cajas es mínima o nula, reforzando la fuerza de esta relación.




Figura 14 - Boxplots variables ERI. Fuente: Elaboración propia.

Columnas ERI: Las variables ERI muestran correlaciones variadas con el Burnout_Score. Atendiendo a los valores precisos del mapa de calor, las correlaciones son:

ERI_10: 0.23 (correlación positiva débil)

ERI_8: 0.32 (correlación positiva moderada-débil)

ERI_9: 0.26 (correlación positiva débil)

ERI_6: -0.29 (correlación negativa moderada-débil)

ERI_7: -0.14 (correlación negativa débil)

ERI_4: -0.10 (correlación negativa débil)

Otras ERI: Muestran correlaciones positivas o negativas muy débiles, cercanas a cero.

Los boxplots de las variables ERI ilustran estas correlaciones. Para variables con correlaciones positivas (ej., ERI_10, ERI_8, ERI_9), aunque son más débiles de lo que se había reportado inicialmente, se puede observar una ligera tendencia de los individuos con Burnout_Score positivo a tener medianas ligeramente más altas en comparación con aquellos con Burnout_Score negativo. Para las variables con correlaciones negativas (ej., ERI_6 y ERI_7), se observaría una ligera tendencia inversa, donde el grupo con Burnout_Score positivo podría mostrar medianas marginalmente más bajas.




Figura 15 - Boxplots variables numéricas. Fuente: Elaboración propia.

Edad (age): Muestra una correlación positiva muy débil (0.07) con el Burnout_Score, apenas perceptible en el mapa de calor.

Ingresos (income): Presenta una correlación positiva débil (0.08) con el Burnout_Score, sugiriendo una tendencia marginal a que mayores ingresos se asocien con un mayor riesgo de burnout. Esto se refleja en un tono azul muy claro en el mapa de calor.

Horas de Trabajo (working_hours): La correlación con el Burnout_Score es una correlación negativa débil (-0.14), mostrando un tono azul claro en el mapa de calor.

Los boxplots para age, income y working_hours confirman una fuerte superposición entre los grupos con y sin burnout. En el caso de age, las medianas y los rangos intercuartílicos son muy similares, lo que sugiere una capacidad discriminativa limitada. Para income, el grupo con burnout presenta una mediana ligeramente superior y una mayor dispersión hacia valores altos. En working_hours, la mediana del grupo con burnout es ligeramente inferior a la observada en el grupo sin burnout, aunque las distribuciones continúan mostrando un amplio solapamiento. En conjunto, la ausencia de una separación clara entre los grupos indica que estas variables, consideradas de forma individual, tienen un poder predictivo limitado para explicar la presencia de burnout en este conjunto de datos.




Figura 16 - Boxplots variables categóricas. Fuente: Elaboración propia.

Características Categóricas (codificadas numéricamente): Las características categóricas codificadas numéricamente presentan una superposición muy elevada entre los grupos con y sin burnout. Los boxplots de status of employment, field of work, federal state, community size, gender e income muestran medianas e intervalos intercuartílicos muy similares, con únicamente ligeras diferencias en algunas variables como income y federal state. La ausencia de una separación visual clara entre ambos grupos respalda la existencia de asociaciones muy débiles con el Burnout_Score y sugiere que estas variables, consideradas de forma individual, poseen una capacidad limitada para discriminar entre individuos con y sin burnout.

En resumen, el análisis bivalente, apoyado por la inspección de los boxplots y el mapa de calor, refuerza que las variables CBI son los factores más influyentes

y distintivos en la clasificación del Burnout_Score. Las variables ERI tienen una influencia moderada a débil, con algunas variables mostrando correlaciones positivas y otras negativas, lo que sugiere una relación más compleja de lo inicialmente reportado. Factores sociodemográficos como la edad, el ingreso y las horas de trabajo, así como las demás variables categóricas, muestran relaciones lineales mucho más débiles con el burnout. Esto sugiere que para esta población de veterinarios, el burnout está predominantemente relacionado con factores psicológicos de agotamiento y, en menor medida, con la percepción de desequilibrio esfuerzo-recompensa, más que con características demográficas o laborales directas en su forma actual.

Dashboard informativo en Tableau

El objetivo principal del dashboard consiste en analizar la distribución del burnout a partir de variables laborales, demográficas y contextuales, con el propósito de identificar el segmento con el mayor nivel de riesgo y apoyar procesos de toma de decisiones orientados a la prevención organizacional.

De manera específica, el dashboard busca:

- Determinar la proporción de individuos con burnout dentro de la población analizada.
- Comparar los niveles de burnout entre distintos sectores laborales.
- Analizar la relación entre cantidad de horas trabajadas y Burnout_Score.
- Evaluar diferencias según estatus laboral o tipo de empleo.
- Identificar variaciones por rango de edad y tamaño de comunidad.
- Explorar posibles patrones geográficos asociados al burnout.
- Determinar diferencias entre género masculino y femenino.
- Analizar la relación entre Burnout_Score y las variables asociadas al modelo ERI.

La solución se orienta a usuarios estratégicos, incluyendo áreas de Recursos Humanos, analistas de datos, responsables de bienestar organizacional y

personal directivo que requiera una visión ejecutiva y exploratoria del fenómeno estudiado.

El análisis fue construido a partir de un dataset estructurado compuesto por variables laborales, demográficas y contextuales. Estas variables respaldan examinar el burnout desde múltiples perspectivas y generar comparaciones entre distintos segmentos poblacionales.

Durante el desarrollo del dashboard se realizaron transformaciones básicas en Tableau, principalmente agregaciones, clasificación de variables y ajustes de categorización. Estas transformaciones permitieron construir indicadores comparables y mejorar la claridad de las visualizaciones sin alterar la lógica original del dataset.

Estructura del dashboard

Con el propósito de facilitar la interpretación de los resultados por parte de usuarios no técnicos, se desarrolló un dashboard interactivo en Tableau estructurado en distintos niveles de análisis. La solución permite explorar la información desde perspectivas demográficas, laborales y geográficas, facilitando la identificación de patrones asociados al burnout y apoyando la toma de decisiones basada en datos.

El dashboard fue diseñado bajo criterios de simplicidad, claridad visual y facilidad de navegación, permitiendo extraer información relevante sin requerir conocimientos avanzados en análisis de datos. La solución se compone de cuatro visualizaciones principales:

- Vista General.
- Distribución porcentual de los ítems CBI.
- Distribución porcentual de los ítems ERI.
- Historia de los datos.

Vista General




Figura 17 - Vista General del dashboard. Fuente: elaboración propia.

La vista general constituye el punto de entrada al dashboard y proporciona una visión resumida de la población analizada. Esta sección está compuesta por cuatro indicadores clave (KPIs) que permiten comprender rápidamente la situación general del conjunto de datos.

Además, incorpora un mapa con la distribución geográfica de la muestra analizada y visualizaciones que muestran la relación del burnout con variables relevantes como el nivel de ingresos y la cantidad de horas trabajadas. Esta combinación de indicadores permite realizar un análisis inicial de los principales factores asociados al fenómeno estudiado.

Distribución porcentual de los ítems CBI

CBI: Distribución porcentual por variable CBI




Figura 18 - Distribución CBI. Fuente: elaboración propia.

La segunda visualización presenta la distribución porcentual de las respuestas correspondientes a los ítems CBI_01 a CBI_06 del Copenhagen Burnout Inventory. Mediante filtros interactivos, el usuario puede segmentar la información según diferentes características demográficas y laborales para analizar cómo varían los niveles de burnout entre distintos grupos de individuos.

Esta vista facilita la identificación de patrones específicos en las respuestas relacionadas con agotamiento personal y permite comprender la contribución de cada ítem dentro de la evaluación general del burnout.

Distribución porcentual de los ítems ERI

ERI: Distribución porcentual por variable ERI




Figura 19 - Distribución ERI. Fuente: elaboración propia.

La tercera visualización presenta la distribución porcentual de los ítems ERI_01 a ERI_10 correspondientes al modelo de Desequilibrio Esfuerzo-Recompensa (Effort-Reward Imbalance).

Al igual que en la visualización de CBI, se incluyen filtros interactivos que permiten explorar las respuestas de distintos segmentos de la población. Esto facilita el análisis de la percepción de esfuerzo laboral, reconocimiento, recompensas y otros factores asociados al estrés ocupacional, permitiendo evaluar su posible relación con los niveles de burnout observados.

Historia de los datos




Figura 20 - Visualización de la historia. Fuente: elaboración propia.

La cuarta visualización corresponde a una historia interactiva compuesta por diferentes puntos de análisis que permiten estudiar individualmente las principales variables del conjunto de datos.

Esta sección facilita una exploración más detallada de factores como género, edad, ingresos, tamaño de comunidad, horas trabajadas, área profesional y ubicación geográfica. Asimismo, incorpora filtros que permiten profundizar en segmentos específicos de la población y obtener una comprensión más completa de las relaciones observadas.

Información adicional sobre cada visualización individual, así como el análisis detallado de las variables, los hallazgos obtenidos y las conclusiones derivadas del dashboard, se presentan en la sección de Anexos II.

Machine Learning

Resultados

Los modelos evaluados fueron entrenados utilizando el conjunto completo de variables predictoras, integrado por los ítems ERI, los ítems CBI y las variables

demográficas y laborales disponibles en el conjunto de datos. En términos generales, los tres algoritmos presentaron un desempeño elevado en el conjunto de prueba, evidenciando una alta capacidad para clasificar correctamente los niveles de riesgo de burnout definidos en la investigación.

El modelo Random Forest alcanzó una balanced accuracy de 0.98 en el conjunto de prueba. La configuración óptima de hiperparámetros correspondió a `max_depth = 10`, `n_estimators = 300`, `min_samples_leaf = 1`, `min_samples_split = 10` y `max_features = 'log2'`.

Por su parte, el modelo de Regresión Logística obtuvo una balanced accuracy de 0.996 utilizando una configuración de `C = 100`, penalización L2 y el algoritmo de optimización liblinear.

De forma similar, el modelo SVM alcanzó una balanced accuracy de 1 con una configuración de `C = 10` y núcleo lineal (linear kernel).

Los resultados obtenidos indican que los tres algoritmos fueron capaces de identificar con un alto nivel de precisión los patrones asociados al riesgo de burnout presentes en el conjunto de datos. No obstante, estos valores deben interpretarse considerando que la variable objetivo `Burnout_Score` fue construida a partir de los ítems CBI, los cuales también fueron incorporados como variables predictoras durante el entrenamiento de los modelos.

=== RF (ERI + CBI + DEMOGRAFICAS) ===

Balanced accuracy: 0.9796092993219245

	precision	recall	f1-score	support
Sin Riesgo	0.99	0.97	0.98	285
Con Riesgo	0.97	0.99	0.98	326
accuracy			0.98	611
macro avg	0.98	0.98	0.98	611
weighted avg	0.98	0.98	0.98	611




Figura 21 - Resultados clasificación del Random Forest. Fuente: elaboración propia.

=== LR (ERI + CBI + DEMOGRAFICAS) ===

Balanced accuracy: 0.9964912280701754

	precision	recall	f1-score	support
Sin Riesgo	1.00	0.99	1.00	285
Con Riesgo	0.99	1.00	1.00	326
accuracy			1.00	611
macro avg	1.00	1.00	1.00	611
weighted avg	1.00	1.00	1.00	611




Figura 22 - Resultados clasificación del Regresión Logística. Fuente: elaboración propia.

=== SVM (ERI + CBI + DEMOGRAFICAS) ===

Balanced accuracy: 1.0

	precision	recall	f1-score	support
Sin Riesgo	1.00	1.00	1.00	285
Con Riesgo	1.00	1.00	1.00	326
accuracy			1.00	611
macro avg	1.00	1.00	1.00	611
weighted avg	1.00	1.00	1.00	611




Figura 23 - Resultados clasificación del SVM. Fuente: elaboración propia.

La importancia por permutación evidenció que los ítems del cuestionario CBI aportaron la mayor contribución predictiva en los tres modelos evaluados. Este resultado es consistente con la construcción metodológica de la variable objetivo, dado que *Burnout_Score* fue definido a partir de las puntuaciones obtenidas en los ítems CBI_01 a CBI_06.

En consecuencia, la elevada relevancia de estas variables era esperable desde una perspectiva estadística y conceptual, ya que representan indicadores

directos del fenómeno que se pretende clasificar. Asimismo, este hallazgo confirma que los componentes del Copenhagen Burnout Inventory constituyen los factores con mayor capacidad discriminante para identificar individuos con niveles elevados de burnout dentro del conjunto de datos analizado.

Por esta razón, los resultados obtenidos deben interpretarse principalmente como una capacidad de clasificación del riesgo de burnout basada en información psicométrica estrechamente relacionada con la definición de la variable objetivo, más que como una capacidad predictiva sustentada exclusivamente en variables demográficas o laborales independientes.




Figura 24 - Importancia por permutación para el Random Forest. Fuente: elaboración propia.




Figura 25 - Importancia por permutación para la Regresión Logística. Fuente: elaboración propia.




Figura 26 - Importancia por permutación para el SVM. Fuente: elaboración propia.

Análisis e interpretación

Los resultados obtenidos muestran que la incorporación de los ítems del Copenhagen Burnout Inventory (CBI) permite clasificar con un alto nivel de precisión los casos de riesgo elevado de burnout definidos mediante el umbral de 50 puntos establecido para la variable *Burnout_Score*. Entre los modelos evaluados, la Regresión Logística y las Máquinas de Vectores de Soporte (SVM) alcanzaron el mejor desempeño, ambos con una *balanced accuracy* de 0.996 y 1 respectivamente. Por su parte, el modelo Random Forest obtuvo una *balanced accuracy* de 0.98, manteniendo igualmente un nivel de desempeño elevado.

El análisis de importancia por permutación evidenció que las variables CBI concentraron la mayor contribución predictiva en los tres modelos. Este resultado es consistente con la metodología utilizada para construir la variable objetivo, ya

que *Burnout_Score* fue definido a partir de las puntuaciones obtenidas en los ítems CBI_01 a CBI_06. En consecuencia, los componentes del instrumento contienen gran parte de la información necesaria para reproducir la clasificación del riesgo de burnout.

Por esta razón, el elevado desempeño observado no debe interpretarse como evidencia de que las variables demográficas y laborales, por sí solas, permiten predecir el burnout con niveles similares de precisión. Más bien, los resultados reflejan la capacidad de los modelos para identificar patrones presentes en indicadores psicométricos directamente relacionados con la definición de la variable objetivo.

Desde una perspectiva aplicada, los modelos desarrollados pueden considerarse herramientas útiles para automatizar la clasificación del riesgo elevado de burnout cuando se dispone de las respuestas individuales a los ítems del cuestionario CBI. No obstante, su utilización debe entenderse como un mecanismo de apoyo analítico para la gestión organizacional y la identificación temprana de posibles situaciones de riesgo, sin sustituir procesos de evaluación clínica o diagnósticos realizados por profesionales especializados.

Asimismo, una eventual implementación en entornos organizacionales requeriría procesos adicionales de validación externa sobre poblaciones diferentes a la muestra utilizada en esta investigación, así como el cumplimiento de principios éticos relacionados con la privacidad, la confidencialidad y la protección de datos personales vinculados al bienestar y la salud mental de los colaboradores.

Recomendaciones

A partir de los resultados obtenidos, se recomienda interpretar los modelos desarrollados como herramientas de clasificación automatizada del riesgo elevado de burnout según la escala Copenhagen Burnout Inventory (CBI), y no como modelos predictivos independientes sustentados exclusivamente en variables externas. Esta consideración resulta fundamental, ya que la variable

objetivo *Burnout_Score* fue construida a partir de los mismos ítems CBI incorporados posteriormente como variables predictoras.

Se recomienda utilizar el modelo completo, compuesto por variables ERI, CBI y variables demográficas y laborales, como una referencia del máximo desempeño alcanzable dentro del conjunto de datos analizado. Los elevados valores de *balanced accuracy* obtenidos por los modelos de Regresión Logística y SVM evidencian la capacidad de los ítems CBI para reproducir con alta precisión la clasificación del riesgo de burnout definida mediante el umbral establecido para la investigación.

Asimismo, se recomienda documentar explícitamente la relevancia predominante de las variables CBI observada en el análisis de importancia por permutación. Este comportamiento debe interpretarse como un resultado metodológicamente coherente con la construcción de la variable objetivo y no como un hallazgo inesperado dentro del proceso de modelado.

Desde una perspectiva aplicada, se recomienda evitar la utilización del modelo como herramienta de diagnóstico clínico. Su aplicación más apropiada corresponde al apoyo analítico para la identificación y clasificación de niveles de riesgo dentro de programas de bienestar organizacional, prevención de riesgos psicosociales y estrategias de People Analytics. Cualquier uso operativo debe complementarse con criterios profesionales, supervisión especializada y mecanismos adecuados de protección de datos personales.

Adicionalmente, se recomienda realizar procesos de validación externa utilizando muestras independientes o nuevos conjuntos de datos procedentes de poblaciones similares. Este procedimiento permitiría evaluar la capacidad de generalización de los modelos y verificar la estabilidad del desempeño observado fuera del entorno de entrenamiento y prueba utilizado en la presente investigación.

6. CONCLUSIONES

Los resultados obtenidos demuestran que es posible aplicar técnicas de analítica de datos para identificar patrones asociados al riesgo de burnout laboral, aportando evidencia sobre el potencial de las herramientas de Business Intelligence y Machine Learning en contextos organizacionales.

El dataset incorpora variables categóricas codificadas, cuya interpretación fue posible mediante el uso del diccionario de datos proporcionado por la fuente original de información. Esto permitió mantener coherencia semántica durante las etapas de transformación, análisis y modelado.

El EDA permitió comprender en profundidad la estructura del conjunto de datos, la distribución de las variables principales y las relaciones existentes con la variable objetivo *Burnout_Score*.

Los resultados obtenidos evidencian que los ítems pertenecientes al CBI y determinadas variables asociadas al modelo ERI constituyen los predictores más influyentes del riesgo de burnout. Asimismo, variables relacionadas con horas de trabajo, edad e ingresos mostraron asociaciones relevantes con el fenómeno analizado.

Adicionalmente, debe señalarse que la variable objetivo utilizada en esta investigación fue construida a partir de los ítems CBI disponibles en el conjunto de datos analizado. Sin embargo, el Copenhagen Burnout Inventory original está compuesto por 19 preguntas agrupadas en tres dimensiones: burnout personal, burnout relacionado con el trabajo y burnout relacionado con clientes o usuarios. En consecuencia, la medición utilizada representa una aproximación parcial al constructo completo de burnout, por lo que futuras investigaciones deberían considerar la aplicación del instrumento completo para obtener una evaluación más integral del fenómeno.

Una de las principales limitaciones encontradas durante el desarrollo del proyecto fue la disponibilidad de fuentes de datos públicas, confiables y suficientemente completas para el estudio del burnout laboral. La localización,

validación y preparación de conjuntos de datos adecuados representó un desafío significativo durante la investigación. Aunque el dataset de profesionales veterinarios de Alemania proporcionó una base sólida para el análisis, la información disponible no contenía la totalidad de las variables deseables para una evaluación integral del burnout.

Dentro de los modelos evaluados, Support Vector Machine presentó los mejores resultados de clasificación bajo las métricas analizadas, particularmente en términos de precisión y capacidad de generalización.

BurnoutGuard, en su forma actual, no es un sistema de aplicación universal. Su capacidad predictiva depende estructuralmente de la disponibilidad simultánea de tres categorías de variables: psicométricas (CBI/ERI), sociodemográficas y laborales documentadas de forma sistemática. Esta condición restringe su implementación a industrias y organizaciones que dispongan de procesos formales de medición y registro en estas tres dimensiones.

En sectores con estructuras laborales flexibles —trabajo remoto, economía de plataformas, autoempleo, consultoría independiente o industrias con jornadas no convencionales— la recopilación de variables como horas trabajadas, estatus de empleo o área funcional resulta inconsistente o directamente inviable, lo que compromete la integridad del modelo. La ausencia o irregularidad de cualquiera de estas variables introduce ruido sistemático que degrada el desempeño clasificatorio.

Adicionalmente, el sistema requiere mediciones periódicas y continuas para mantener su validez operativa. Las variables psicométricas, en particular, no son estables en el tiempo: el estado de burnout de un individuo evoluciona en función de cambios en la carga laboral, el entorno organizacional y factores externos. Un modelo entrenado sobre una muestra puntual pierde representatividad si no se actualiza con nuevas rondas de recolección de datos. Esto implica que la implementación de BurnoutGuard en un entorno organizacional real exige un compromiso sostenido con procesos de encuestación, gestión de datos y

reentrenamiento periódico de modelos, lo que representa una carga operativa significativa que debe evaluarse antes de escalar la solución.

Como línea de investigación futura, resulta pertinente desarrollar modelos alternativos basados en las variables del cuestionario ERI, con el fin de analizar su capacidad explicativa y comparar sus resultados con los obtenidos mediante la variable objetivo derivada del CBI. Esta comparación permitiría establecer un marco de referencia entre distintos enfoques de medición del riesgo psicosocial y del burnout laboral.

Asimismo, se recomienda explorar la construcción de una variable objetivo multidimensional que integre factores psicométricos, laborales y sociodemográficos. Un enfoque de este tipo permitiría representar el fenómeno del burnout desde una perspectiva más amplia, incorporando factores contextuales que actualmente no participan directamente en la definición de la variable objetivo.

Finalmente, la investigación permitió identificar una consideración metodológica relevante relacionada con la construcción de la variable objetivo y el uso de los indicadores psicométricos durante el entrenamiento de los modelos. La variable Burnout_Score fue construida a partir de las respuestas obtenidas en los ítems CBI_01 a CBI_06 correspondientes a la dimensión de burnout personal, y dichos ítems también fueron incorporados como variables predictoras dentro de los modelos desarrollados.

Esta decisión metodológica resulta coherente con el planteamiento conceptual de la investigación, dado que las variables psicométricas forman parte de las dimensiones consideradas para la detección del riesgo de burnout junto con las variables laborales y sociodemográficas. En consecuencia, el elevado desempeño alcanzado por los modelos refleja principalmente su capacidad para identificar patrones presentes en indicadores directamente relacionados con la definición del fenómeno estudiado.

Asimismo, este hallazgo permitió evidenciar una diferencia entre el objetivo inicial del estudio y el alcance efectivo de los modelos desarrollados. La

investigación se planteó originalmente como un mecanismo de detección temprana del riesgo de burnout mediante la integración de variables sociodemográficas, laborales y psicométricas. Sin embargo, al construirse la variable objetivo a partir de los propios indicadores CBI, los resultados obtenidos representan principalmente una capacidad de clasificación basada en mediciones psicométricas ya disponibles.

Por ello, futuras investigaciones deberán evaluar modelos alternativos que excluyan los ítems CBI o incorporen variables objetivo construidas a partir de múltiples dimensiones, con el fin de estimar con mayor precisión la capacidad predictiva independiente de los factores laborales, sociodemográficos y psicosociales asociados al burnout.

7. BIBLIOGRAFÍA

- Akerlof, G. A., & Yellen, J. L. (1990). The fair wage-effort hypothesis and unemployment. *The Quarterly Journal of Economics*, 105(2), 255–283. <https://doi.org/10.2307/2937787>
- Bakker, A. B., & Demerouti, E. (2007). The job demands-resources model: State of the art. *Journal of Managerial Psychology*, 22(3), 309–328. <https://doi.org/10.1108/02683940710733115>
- Becker, G. S. (1964). *Human capital: A theoretical and empirical analysis, with special reference to education*. National Bureau of Economic Research.
- Boudreau, J. W., & Cascio, W. F. (2017). Human capital analytics: Why are we not there? *Journal of Organizational Effectiveness: People and Performance*, 4(2), 119–126. <https://doi.org/10.1108/JOEPP-03-2017-0021>
- Chapman, A. J., Rohlf, V. I., Moser, A. Y., & Bennett, P. C. (2024). Factores organizativos que afectan al agotamiento en enfermeros veterinarios: una revisión sistemática. *Anthrozoös*, 37(4), 651–686. <https://doi.org/10.1080/08927936.2024.2333161>
- Chapman, A. J., Rohlf, V. I., & Bennett, P. C. (2024). Organizational Factors Affecting Burnout in Veterinary Nurses: A Systematic Review. *Anthrozoös*, 37(4), 651–686. <https://doi.org/10.1080/08927936.2024.2341235>
- Claessens, B. J. C., Van Eerde, W., Rutte, C. G., & Roe, R. A. (2007). A review of the time management literature. *Personnel Review*, 36(2), 255–276. <https://doi.org/10.1108/00483480710726136>
- Davenport, T. H., Harris, J., & Shapiro, J. (2010). Competing on talent analytics. *Harvard Business Review*, 88(10), 52–58.
- Delgado Carabajo, M. G., Sánchez Arrobo, S. J., Sánchez Armijos, T. M., Zapata Saavedra, M. L., Mero Salavarría, A. F., & Romero Cali, K. L. (2025).

Factores de riesgo asociados al síndrome de burnout en médicos veterinarios y su impacto en el bienestar emocional y en el desempeño clínico. *Ciencia Latina Revista Científica Multidisciplinar*, 9(5), 204-232.

https://doi.org/10.37811/cl_rcm.v9i5.19650

European Bioinformatics Institute. (2024). *S-EPMC11421818* [Dataset]. BioStudies. <https://www.ebi.ac.uk/biostudies/europepmc/studies/S-EPMC11421818>

Few, S. (2013). *Information dashboard design: Displaying data for at-a-glance monitoring* (2nd ed.). Analytics Press.

Flexera. (2025, March 19). *The latest cloud computing trends: Flexera 2025 State of the Cloud report*. <https://www.flexera.com/blog/finops/the-latest-cloud-computing-trends-flexera-2025-state-of-the-cloud-report/>

Google Cloud. (n.d.). *Cloud for Healthcare and Life Sciences (HCLS)*. Retrieved May 24, 2026, from <https://cloud.google.com/solutions/healthcare-life-sciences>

Google Cloud. (n.d.). *Financial services*. Retrieved May 24, 2026, from <https://cloud.google.com/solutions/financial-services>

Google Cloud. (n.d.). *Google Public Sector*. Retrieved May 24, 2026, from <https://cloud.google.com/public-sector>

Hassard, J., Teoh, K. R. H., Visockaite, G., Dewe, P., & Cox, T. (2018). The cost of work-related stress to society: A systematic review. *Journal of Occupational Health Psychology*, 23(1), 1–17. <https://doi.org/10.1037/ocp0000069>

Hatch, P. H., Winefield, H. R., Christie, B. A., & Lievaart, J. J. (2011). Workplace stress, mental health, and burnout of veterinarians in Australia. *Australian Veterinary Journal*, 89(11), 460–468. <https://doi.org/10.1111/j.1751-0813.2011.00833.x>

- IBM. (n.d.). *What is data leakage in machine learning?* IBM Think. Retrieved June 2, 2026, from <https://www.ibm.com/think/topics/data-leakage-machine-learning>
- Kristensen, T. S., Borritz, M., Villadsen, E., & Christensen, K. B. (2005). The Copenhagen Burnout Inventory: A new tool for the assessment of burnout. *Work & Stress*, 19(3), 192–207. <https://doi.org/10.1080/02678370500297720>
- Laney, D. (2001). *3D data management: Controlling data volume, velocity and variety*. META Group Research Note.
- Leiter, M. P., & Maslach, C. (2016). *Burnout at work: A psychological perspective*. Psychology Press.
- Leiter, M. P., & Maslach, C. (2016). *Burnout and engagement: Contributions to a new vision*. *Burnout Research*, 3(4), 55-57.
- LinkedIn. (2023, 19 de julio). Visualización de datos para el agotamiento y el equilibrio entre el trabajo y la vida personal. LinkedIn Advice. [Visualización de datos para el agotamiento y el equilibrio entre el trabajo y la vida personal](#)
- Lohrmann, D. (2025, April). *Where is government when it comes to cloud in 2025?* GovTech. <https://www.govtech.com/blogs/lohrmann-on-cybersecurity/where-is-government-when-it-comes-to-cloud-in-2025>
- Marler, J. H., & Boudreau, J. W. (2017). An evidence-based review of HR Analytics. *The International Journal of Human Resource Management*, 28(1), 3–26. <https://doi.org/10.1080/09585192.2016.1244699>
- Maslach, C., Schaufeli, W. B., & Leiter, M. P. (2001). Job burnout. *Annual Review of Psychology*, 52(1), 397–422. <https://doi.org/10.1146/annurev.psych.52.1.397>

- Maslach, C., & Jackson, S. E. (1981). The measurement of experienced burnout. *Journal of Occupational Behavior*, 2(2), 99–113. <https://doi.org/10.1002/job.4030020205>
- Maslach, C., & Leiter, M. P. (2016). Understanding the burnout experience: Recent research and its implications for psychiatry. *World Psychiatry*, 15(2), 103–111. <https://doi.org/10.1002/wps.20311>
- Mastenbroek, N. J. J. M., Jaarsma, A. D. C., Scherpbier, A. J. J. A., Van Beukelen, P., & Demerouti, E. (2014). Burnout and engagement, and its predictors in young veterinary professionals: The influence of gender. *Veterinary Record*, 174(6), Article 144. <https://doi.org/10.1136/vr.101762>
- Microsoft. (n.d.). *Power BI pricing*. Retrieved May 24, 2026, from <https://www.microsoft.com/en-us/power-platform/products/power-bi/pricing>
- Microsoft Azure. (n.d.). *Azure Data Factory pricing (Data Pipeline)*. Retrieved May 24, 2026, from <https://azure.microsoft.com/en-us/pricing/details/data-factory/data-pipeline/>
- Microsoft Azure. (n.d.). *Azure Data Lake Storage pricing*. Retrieved May 24, 2026, from <https://azure.microsoft.com/en-us/pricing/details/storage/data-lake/>
- Microsoft Azure. (n.d.). *Azure Databricks pricing*. Retrieved May 24, 2026, from <https://azure.microsoft.com/en-us/pricing/details/databricks/>
- Microsoft Azure. (n.d.). *Azure Key Vault pricing*. Retrieved May 24, 2026, from <https://azure.microsoft.com/en-us/pricing/details/key-vault/>
- Microsoft Azure. (n.d.). *Azure Monitor pricing*. Retrieved May 24, 2026, from <https://azure.microsoft.com/en-us/pricing/details/monitor/>
- Microsoft Azure. (n.d.). *Azure Synapse Analytics pricing*. Retrieved May 24, 2026, from <https://azure.microsoft.com/en-us/pricing/details/synapse-analytics/>

- Microsoft Learn. (2025, October 6). *Online endpoints for real-time inference (Azure Machine Learning)*. <https://learn.microsoft.com/en-us/azure/machine-learning/concept-endpoints-online?view=azureml-api-2>
- Salvagioni, D. A. J., Melanda, F. N., Mesas, A. E., González, A. D., Gabani, F. L., & Andrade, S. M. (2017). Physical, psychological and occupational consequences of job burnout: A systematic review of prospective studies. *PLoS ONE*, 12(10), e0185781. <https://doi.org/10.1371/journal.pone.0185781>
- Scikit-learn. (n.d.). *sklearn.metrics.f1_score*. Retrieved May 2026, from https://scikit-learn.org/stable/modules/generated/sklearn.metrics.f1_score.html
- Schwerdtfeger, K. A., Bahramsoltani, M., Lahrgang, P., & Glaesmer, H. (2020). Burnout, depression and suicidal ideation in German veterinarians. *Veterinary Record*, 186(15), Article 485. <https://doi.org/10.1136/vr.105437>
- Sharda, R., Delen, D., & Turban, E. (2020). *Analytics, data science, & artificial intelligence: Systems for decision support* (11th ed.). Pearson.
- Siegrist, J. (1996). Adverse health effects of high-effort/low-reward conditions. *Journal of Occupational Health Psychology*, 1(1), 27–41. <https://doi.org/10.1037/1076-8998.1.1.27>
- Synergy Research Group. (2025, November 19). *Cloud market share trends—Big three together hold 63% while Oracle and the neoclouds inch higher*. <https://www.srgresearch.com/articles/cloud-market-share-trends-big-three-together-hold-63-while-oracle-and-the-neoclouds-inch-higher>
- U.S. Department of the Treasury. (2024, July 17). *Treasury and the Financial Services Sector Coordinating Council publish new resources on effective practices for secure cloud adoption*. <https://home.treasury.gov/news/press-releases/jy2467>

World Health Organization. (2019). *Burn-out an occupational phenomenon: International Classification of Diseases (ICD-11)*.
<https://www.who.int/standards/classifications/frequently-asked-questions/burn-out-an-occupational-phenomenon>

8. ANEXOS.

ANEXO I:

Acceso al repositorio y reproducción del proyecto

Con el propósito de facilitar la revisión, validación y reproducción de los resultados obtenidos durante el desarrollo del TFM, se pone a disposición el repositorio oficial del proyecto en GitHub.

[Repositorio de GitHub con los notebooks del EDA y los modelos de machine Learning.](#)

Estructura del repositorio

El repositorio se encuentra organizado en las siguientes carpetas principales:

1. Carpeta *dashboard*

Contiene los archivos desarrollados en Tableau Desktop utilizados para la construcción de los dashboards presentados en este trabajo.

Estos archivos pueden abrirse localmente utilizando Tableau Desktop para revisar las visualizaciones, filtros, historias y dashboards desarrollados.

2. Carpeta *docs*

Contiene una copia digital del documento escrito del TFM y documentación complementaria relacionada con el proyecto.

3. Carpeta *python-TFM*

Contiene el desarrollo completo del proyecto en Python.

3.1 Carpeta *notebooks*

Incluye los notebooks de Jupyter utilizados durante las distintas fases del proyecto:

a) *dashboard.ipynb*

Este notebook genera el archivo de datos utilizado como fuente de información para Tableau. Su ejecución permite recrear los conjuntos de datos necesarios para alimentar los dashboards desarrollados.

b) *G11_EDA.ipynb*

Contiene el proceso completo de análisis exploratorio de datos (EDA), incluyendo:

- Carga de datos.
- Limpieza y validación.
- Transformación de variables.
- Creación de la variable objetivo.
- Generación de estadísticas descriptivas.
- Visualizaciones exploratorias.

Durante su ejecución se genera el archivo:

[germany.veterinarians.csv](#)

Este archivo constituye:

- La fuente de datos utilizada por dashboard.ipynb.
- La fuente de datos utilizada por G11_ML.ipynb.

Por esta razón, se recomienda ejecutar este notebook antes de ejecutar los demás componentes del proyecto.

c) G11_ML.ipynb

Contiene el desarrollo completo de los modelos de Machine Learning utilizados en la investigación, incluyendo:

- Preparación de datos.
- División entrenamiento/prueba.
- Entrenamiento de modelos.
- Optimización de hiperparámetros.
- Evaluación de desempeño.
- Análisis de importancia de variables.
- Generación de métricas y resultados finales.

Procedimiento de instalación y ejecución

Requisitos previos

Se recomienda disponer de los siguientes componentes:

- Visual Studio Code.
- Python 3.11 o superior.
- Extensión Jupyter para Visual Studio Code.
- Git.

Paso 1. Clonar el repositorio

Abrir una terminal de Visual Studio Code y ejecutar:

```
git clone https://github.com/davidmejiacascante/G11_TFM_NEXT_2026.git
```

Posteriormente acceder al directorio del proyecto:

```
cd G11_TFM_NEXT_2026
```

Paso 2. Crear un entorno virtual

Se recomienda utilizar un entorno virtual independiente para evitar conflictos entre dependencias.

Windows:

```
python -m venv .venv
```

Activación:

```
.venv\Scripts\activate
```

Linux/MacOS:

```
python3 -m venv .venv  
source .venv/bin/activate
```

Paso 3. Instalar dependencias

Con el entorno virtual activado, instalar las bibliotecas necesarias mediante el archivo requirements.txt:

```
pip install -r requirements.txt
```

Paso 4. Abrir el proyecto en Visual Studio Code

Abrir la carpeta del proyecto:

```
code .
```

Seleccionar el intérprete de Python correspondiente al entorno virtual creado.

Paso 5. Ejecutar los notebooks

Para reproducir completamente el flujo de trabajo se recomienda el siguiente orden de ejecución:

1. G11_EDA.ipynb
2. dashboard.ipynb
3. G11_ML.ipynb

Este orden garantiza la correcta generación de los archivos intermedios requeridos por las etapas posteriores del proyecto.

Reproducibilidad

Siguiendo los pasos descritos anteriormente es posible reproducir:

- El proceso completo de limpieza y transformación de datos.
- El análisis exploratorio (EDA).
- La construcción de dashboards.

- El entrenamiento y evaluación de modelos de Machine Learning.
- Los resultados presentados en este Trabajo Final de Máster.

ANEXO II:

[Dashboard Análisis de Burnout Grupo 11 para el TFM.](#)

ANEXO III: Implementación de BurnoutGuard en cloud.

Para una futura implementación organizacional de BurnoutGuard, deben considerarse dos escenarios principales. El primero corresponde a una implementación en una empresa nueva, donde existe mayor libertad para seleccionar tecnologías, arquitecturas y prácticas alineadas con los requerimientos del proyecto. El segundo escenario corresponde a la implementación dentro de una organización ya existente, situación en la que la solución debe adaptarse a los recursos tecnológicos, políticas corporativas y ecosistemas previamente establecidos.

Dentro de una arquitectura cloud, comprender el contexto de implementación resulta más importante que determinar únicamente qué servicio tecnológico es “mejor”. Desde la perspectiva de ingeniería de datos y arquitectura empresarial, es necesario evaluar no solo aspectos técnicos, sino también criterios asociados a viabilidad de negocio (Business Viability), integración organizacional, costos operativos y sostenibilidad de largo plazo.

En este contexto, el escenario de implementación define si la solución es adecuada a un modelo de diseño ideal (Greenfield) o a un modelo de adaptación organizacional (Brownfield).

Escenario A: Empresa nueva (Greenfield).

En un escenario *Greenfield*, BurnoutGuard puede diseñarse sin dependencias tecnológicas heredadas, contratos previos, restricciones de identidad corporativa o plataformas de analítica preexistentes.

Este contexto confirma seleccionar el proveedor cloud bajo criterios asociados principalmente a:

- Eficiencia técnica.
- Costos operacionales.
- Velocidad de implementación.
- Disponibilidad de servicios administrados (fully managed).
- Capacidades serverless.
- Reducción de complejidad operativa.

La flexibilidad característica de este escenario favorece plataformas con capacidades maduras de analítica serverless y tiempos reducidos de adopción para equipos pequeños o medianos.

No obstante, aunque el escenario *Greenfield* ofrece mayor libertad tecnológica, el mercado cloud mantiene una fuerte concentración en los principales proveedores globales. Según Synergy Research Group (2025), AWS, Azure y Google concentran aproximadamente el 63% del gasto mundial en infraestructura cloud, con participaciones cercanas al 29%, 20% y 13% respectivamente.

Esta concentración impacta directamente aspectos como disponibilidad de talento especializado, ecosistemas de partners, soporte empresarial y adopción de patrones arquitectónicos estándar.

Escenario B: Empresa existente (Brownfield) – Escenario seleccionado.

En un escenario *Brownfield*, la prioridad deja de ser la selección del “mejor” proveedor cloud y pasa a centrarse en la selección del proveedor tecnológicamente viable dentro del contexto organizacional existente.

Las organizaciones suelen contar con:

- Proveedores cloud previamente definidos.
- Contratos empresariales activos.
- Plataformas de BI corporativas.
- Políticas de seguridad y gobierno establecidas.
- Sistemas centralizados de identidad y acceso.

Por esta razón, la arquitectura propuesta debe alinearse con el modelo operativo (*Operating Model*) de la organización.

Este escenario representa el enfoque seleccionado para BurnoutGuard, considerando además que estudios como el *Flexera 2025 State of the Cloud Report* evidencian una adopción creciente de estrategias híbridas y multicloud dentro del entorno empresarial.

En consecuencia, BurnoutGuard fue diseñado para un escenario Brownfield utilizando Microsoft Azure como proveedor cloud principal.

Objetivo organizacional de BurnoutGuard.

Dentro de una organización real, BurnoutGuard funcionaría como una plataforma de *People Analytics* orientada a:

- Ingerir datos heterogéneos provenientes de encuestas, HRIS/ERP, registros operativos y métricas de engagement.
- Normalizar y gobernar datos organizacionales.
- Ejecutar procesos analíticos descriptivos y predictivos.
- Exponer resultados mediante dashboards ejecutivos para Recursos Humanos y liderazgo.
- Desplegar inferencia bajo demanda mediante modelos de Machine Learning con trazabilidad y control de acceso.

Clasificación del workload.

La arquitectura propuesta utiliza principalmente un patrón de procesamiento *batch*, complementado con capacidades serverless para ejecución bajo demanda

Paradigma arquitectónico propuesto

1. **Batch (núcleo operativo):** Procesamiento periódico para ingesta de datos, ETL/ELT, ingeniería de características y actualización de datasets analíticos.
2. **Serverless (complementario):** Uso de orquestación y ejecución puntual de procesos sin infraestructura persistente.
3. **Analytics (capa de consumo):** Capa SQL/warehouse orientada a BI, segmentación y reporting corporativo con control de acceso centralizado.

El uso de procesamiento *streaming* no fue considerado prioritario debido a que el dataset del TFM corresponde principalmente a encuestas y procesamiento periódico. No obstante, este enfoque podría incorporarse en futuras evoluciones si la organización integra eventos en tiempo real como telemetría, tickets o métricas operativas continuas.

Arquitectura Cloud propuesta.




Figura 27 - Arquitectura Cloud.

La arquitectura diseñada incorpora los siguientes componentes:

- Data Sources: Sistemas HRIS/ERP, encuestas CBI/ERI, archivos CSV y APIs internas.
- Azure Data Factory: Servicio utilizado para procesos de ingesta batch y orquestación de pipelines.
- Azure Data Lake Storage Gen2: Almacenamiento estructurado bajo arquitectura Bronze/Raw y Silver/Curated.
- Azure Databricks: Plataforma utilizada para ETL, EDA e ingeniería de características mediante Apache Spark.
- Azure Synapse Analytics: Capa Gold/Serving utilizada para consultas SQL, BI y consumo analítico downstream.
- Azure Machine Learning: Servicio enfocado a entrenamiento, registro de modelos y procesos MLOps.
- Managed Online Endpoint (Azure ML): Servicio utilizado para inferencia y publicación de resultados analíticos.
- Power BI: Plataforma utilizada para dashboards orientados a Recursos Humanos, liderazgo y análisis organizacional.

Justificación tecnológica de Azure para Escenario Brownfield.

Azure representa una elección racional en escenarios organizacionales donde la empresa ya opera dentro del ecosistema Microsoft.

La integración nativa entre Azure, Power BI y Microsoft Entra ID facilita:

- Gestión centralizada de identidad y acceso.
- Integración empresarial simplificada.

- Control de acceso sobre datos sensibles.
- Gobierno corporativo alineado con estándares organizacionales.

Adicionalmente, Azure posee una fuerte presencia empresarial global, lo que reduce riesgos asociados a continuidad tecnológica (*Vendor Viability*) y facilita la contratación de talento especializado y partners tecnológicos.

Estimación de costes.

Los costos asociados a la arquitectura dependen de factores como región, volumen de datos, acuerdos corporativos y frecuencia de procesamiento.

Supuestos de dimensionamiento

La estimación considera un escenario correspondiente a una empresa mediana con:

- Una ejecución ETL diaria.
- Un entrenamiento semanal de modelos.
- Inferencia diaria por segmentos organizacionales.
- Aproximadamente 1 TB de almacenamiento en ADLS Gen2.
- Uso moderado de observabilidad y retención de logs.

Componentes con mayor impacto económico

Los componentes que típicamente representan mayor costo operativo son:

- Azure Databricks.
- Synapse Analytics dedicado.
- Azure Monitor / Log Analytics.

El principal riesgo financiero proviene del uso ineficiente de clústeres de cómputo persistentes y de un crecimiento no controlado de telemetría y observabilidad.

Estimación mensual aproximada.

- ADLS Gen2 (1 TB Hot/Cool + transacciones): depende de tier/operaciones; es de los rubros más bajos relativo a compute.
- ADF (orquestación + copy DIU-hours): bajo-medio; paga por actividad/DIU-hour.
- Databricks (jobs clusters auto-terminate): medio-alto (depende de horas de clúster).
- Synapse: serverless SQL: ~\$5/TB procesado (referencias de mercado para serverless; validar por región).
- Azure ML: plataforma sin fee adicional; costo recae en compute y servicios asociados (storage, registry, insights).

- Power BI Pro: \$14 usuario/mes (facturación anual según página de Microsoft).

El rango agregado estimado para una empresa mediana con uso moderado oscila entre USD \$500 y USD \$2,500 mensuales, dependiendo principalmente del uso de cómputo analítico y observabilidad.

Calculadora de Azure:

Your Estimate

✓ Azure Databricks	①	All-Purpose Compute Workload, Standard Tier, ...	Upfront: \$0.00	Monthly: \$142.32	Annual: \$1,707.84
✓ Storage Accounts	①	Data Lake Storage Gen2, Standard, LRS Redund...	Upfront: \$0.00	Monthly: \$22.38	Annual: \$268.56
✓ Azure Data Factory	①	Azure Data Factory V2 Type, Data Pipeline Servi...	Upfront: \$0.00	Monthly: \$0.26	Annual: \$3.06
✓ Azure Synapse Analytics	①	Tier: Compute Optimized Gen2, Dedicated SQL ...	Upfront: \$0.00	Monthly: \$648.48	Annual: \$7,781.70
✓ Azure Machine Learning	①	1 D3 v2 (4 Core(s), 14 GB RAM) x 240 Hours, Pa...	Upfront: \$0.00	Monthly: \$54.96	Annual: \$659.52
✓ Power BI Embedded	①	1 node(s) x 240 Hours, Node type: A1, 1 Virtual ...	Upfront: \$0.00	Monthly: \$241.94	Annual: \$2,903.33
✓ Microsoft Entra ID (formerly Azure AD)	①	Premium P1 - 0 users, Premium P2 - 0 users, En...	Upfront: \$0.00	Monthly: \$96.00	Annual: \$1,152.00
✓ Key Vault	①	Vault: 100 operations, 0 advanced operations, 0...	Upfront: \$0.00	Monthly: \$0.03	Annual: \$0.36
✓ Azure Monitor	①	Log analytics: Log Data Ingestion: 0 GB Daily Au...	Upfront: \$0.00	Monthly: \$57.50	Annual: \$690.00
✓ Microsoft Cost Management	①	No charge for managed Azure spend.	Upfront: \$0.00	Monthly: \$0.00	Annual: \$0.00
✓ Microsoft Defender for Cloud	①	Microsoft Defender for Cloud Security Posture ...	Upfront: \$0.00	Monthly: \$0.00	Annual: \$0.00
✓ Microsoft Purview	①	Data Security: 1 Assets x 31 days, 1 User activiti...	Upfront: \$0.00	Monthly: \$145.60	Annual: \$1,747.19

Support

SUPPORT: Basic (Included) ① \$0.00

Select your program/offer

LICENSING PROGRAM: Microsoft Customer Agreement (MCA) ① [Log in](#) to see your Azure agreement pricing.

☐ Show Dev/Test Pricing ①

Estimated upfront cost	\$0.00
Estimated monthly cost	\$1,409.46
Estimated annual cost	\$16,913.57

Figura 28 - Tabla de costos de Azure.

Estrategias de optimización.

Se proponen las siguientes estrategias de optimización:

- Uso de *auto terminate* en clústeres de Databricks.
- Uso de *jobs clusters* en lugar de clústeres persistentes.
- Preferencia por Synapse Serverless en escenarios de exploración ligera.
- Pausa automática de pools dedicados fuera de horario operativo.
- Control de retención y volumen de logs en Azure Monitor.

- Implementación de prácticas FinOps mediante presupuestos, alertas y etiquetado de costos.

Consideraciones adicionales.

Escalabilidad y disponibilidad

La arquitectura fue diseñada para escalar horizontalmente mediante servicios administrados y capacidades serverless.

En el contexto europeo del dataset analizado, se recomienda utilizar regiones cloud pertenecientes a la Unión Europea para cumplir requisitos de residencia y regulación de datos.

Seguridad y control de acceso.

La seguridad se implementa mediante:

- Microsoft Entra ID para identidad centralizada.
- RBAC para control de acceso granular.
- Azure Key Vault para gestión de secretos y credenciales.
- Azure Monitor y Log Analytics para auditoría y observabilidad.

Gobierno del dato.

La arquitectura utiliza un modelo de Data Lake estructurado en capas Bronze, Silver y Gold, facilitando:

- Trazabilidad.
- Control de calidad.
- Gobernanza.
- Separación entre datos crudos, transformados y analíticos.

Este enfoque mantiene coherencia con el flujo desarrollado dentro del notebook del proyecto:

raw → clean → eda → serving

Mantenimiento y MLOps

La solución contempla prácticas de mantenimiento asociadas a:

- Versionamiento de pipelines.
- CI/CD para datos y modelos.
- Registro de modelos.

- Monitoreo de model drift.
- Actualización periódica de inferencia y datasets analíticos.

ANEXO IV: Dashboard en Tableau

Descripción de los datos

El análisis se construyó a partir de un dataset estructurado que contiene información de individuos vinculada con variables laborales, demográficas y de contexto. Estas variables permiten estudiar el burnout desde distintas perspectivas y generar comparaciones entre segmentos.

- Burnout_Score: variable binaria que identifica la presencia o ausencia de burnout.
- Field of Work: área de trabajo del individuo.
- Status of Employment: situación laboral o tipo de empleo.
- Rango de Edad: clasificación de la población por grupos etarios.
- Community Size: tamaño de la comunidad en la que se ubica el individuo.
- Federal State: referencia geográfica utilizada para el análisis territorial.
- Gender: Género masculino o femenino
- ERI: Desequilibrio Esfuerzo – Recompensa.
- CBI

Variable	Tipo	Categoría / codificación
Gender	Categórica nominal dicotómica	1 = male 2 = female.
birth year	Númerica discreta (año); en el estudio se transforma a ordinal por grupos etarios	Se agrupó en: 22–29, 30–39, 40–49, 50–59, 60–69.
status of employment	Categórica nominal politómica; en el análisis se redujo a dicotómica	1 = self-employed 2 = employed 3 = unemployed by choice 4 = currently looking for a job 5 = parental leave 6 = working in a nonveterinarian field 7 = retired 8 = incapacitated for employment 9 = no lo pude confirmar con seguridad
field of work	Categórica nominal politómica; en el análisis se redujo a dicotómica.	1 = small animal medicine 2 = horses 3 = farm animals 4 = mixed practice 5 = food hygiene(general) 6 = food hygiene in slaughterhouse 7 = industry – research & development 8 = industry – technical service 9 = industry – field service 10 = public health 11 = research 12 = university 13 = zoo animals 14 = other
federal state	Categórica nominal politómica	1 = BadenWürttemberg 2 = Bavaria (Bayern) 3 = Berlin 4 = Brandenburg 5 = Bremen 6 = Hamburg 7 = Hessen 8 = Mecklenburg-Vorpommern 9 = Niedersachsen 10 = North Rhine-Westphalia 11 = Rheinland-Pfalz 12 = Saarland 13 = Saxony (Sachsen) 14 = Saxony-Anhalt 15 = Schleswig-Holstein 16= Thuringia.
community size	Categórica ordinal	<5,000, <20,000, <100,000, >100,000 habitantes.
income	Categórica ordinal	<€1,000, <€2,000, <€3,000, <€4,000, <€5,000, >€5,000, con opción de no informar.

working hours	Variable mixta: respuesta abierta numérica/textual; luego ordinal agrupada	Se agruparon en: 0–20, 21–40, 41–60, 61–80, >80 horas/semana
ERI_1 – ERI_10	Catagórica ordinal tipo Likert de 4 niveles	1 = strongly disagree, 2 = disagree, 3 = agree, 4 = strongly agree.
CBI_01 – CBI_06 Burnout Score	CBI_01 – CBI_06: Catagórica ordinal tipo Likert de 4–5 niveles Burnout Score: Es catagórica, pero sale del promedio. Los valores por encima de la puntuación 50 se categorizaron como 1 (positivos por burnout) y por debajo	CBI 01 a 06 1 = Sí, a menudo, 2 = Sí, a veces 3 = No estoy seguro 4 = Rara vez 5 = No, nunca Burnout Score 1 = con burnout 0 = sin Burnout

Tabla 6 - Diccionario de variables. Fuente: elaboración propia.

Se realizaron transformaciones básicas en Tableau, principalmente agregaciones, clasificación de variables y ajustes de categorización. Esto permitió construir indicadores comparables y mejorar la claridad de las visualizaciones sin alterar la lógica del dataset original.

Principales indicadores




Figura 29 - KPI's del dashboard. Fuente: elaboración propia.

Los indicadores clave del dashboard ofrecen una lectura inicial del nivel de burnout en la población analizada. El principal indicador corresponde al porcentaje de personas clasificadas con burnout, el cual permite dimensionar la magnitud general del fenómeno dentro de la muestra. En esta vista también se incluye el total de registros analizados, la cantidad de casos con burnout, el promedio de edad y el promedio de horas trabajadas, lo que permite contextualizar los resultados antes de profundizar en los distintos segmentos laborales, demográficos y geográficos.

Esta hoja funciona como punto de partida del dashboard, ya que resume la situación general de la muestra y permite al usuario explorar los datos mediante filtros interactivos. Los filtros incorporados facilitan el análisis por género, área de trabajo y rango de edad, permitiendo observar cómo varían los indicadores principales según las características seleccionadas.

A partir de esta interacción se identifican algunos hallazgos relevantes. Uno de los más importantes es la diferencia en el porcentaje de burnout positivo entre hombres y mujeres. En la muestra analizada, los hombres presentan un porcentaje de burnout positivo de 13,6 %, mientras que las mujeres presentan un valor de 39,7 %. Esta diferencia debe interpretarse con cautela, ya que la muestra no está distribuida de forma equilibrada por género: existe una mayor cantidad de registros correspondientes a mujeres, lo cual puede influir en la estabilidad y representatividad de los porcentajes observados.

Además, la vista permite observar diferencias en los promedios de edad y de horas trabajadas entre los grupos filtrados. Estos indicadores complementarios son útiles para contextualizar el comportamiento del burnout, ya que permiten relacionarlo con características laborales y sociodemográficas de la población.

En conjunto, los KPI no solo resumen el fenómeno, sino que también orientan la exploración posterior del dashboard hacia posibles patrones o segmentos de interés.

Distribución del burnout




Figura 30 - Indicador de burnout. Fuente: elaboración propia.

Esta visualización muestra la relación entre individuos con y sin burnout dentro del conjunto analizado. Su propósito es ofrecer una lectura rápida de la magnitud del fenómeno antes de revisar sus posibles diferencias por sector, edad, género, tipo de empleo o ubicación.

Burnout por área de trabajo




Figura 31 - Burnout por área de trabajo. Fuente: elaboración propia.

El indicador de burnout por área de trabajo permitió comparar el nivel de burnout entre las distintas áreas de trabajo, identificando aquellas áreas con mayor concentración de riesgo. En la imagen se ven en rojo los casos de burnout positivo dentro de cada una de las áreas y en azul las negativas.

Este análisis identifica las áreas críticas donde el burnout es más prevalente, lo que sugiere la posible influencia de condiciones laborales específicas, como la carga de trabajo, el nivel de exigencia o el entorno organizacional, lo que permite priorizar áreas de intervención y orientar estrategias enfocadas en mejorar el bienestar laboral dentro de las áreas más afectadas.

Burnout por rango de edad




Figura 32 - Burnout por rango de edad. Fuente: elaboración propia.

El **burnout por rango de edad** muestra la forma en que el nivel de burnout varía entre distintos grupos etarios.

Este análisis favorece la identificación de patrones asociados a etapas específicas de la vida laboral, evidenciando que ciertos grupos pueden presentar una mayor vulnerabilidad al burnout. Estas diferencias pueden estar relacionadas con factores como la experiencia laboral, el nivel de responsabilidad o el momento profesional en el que se encuentra el individuo.

Este gráfico adiciona una perspectiva demográfica clave para comprender el fenómeno del burnout y permite orientar estrategias de intervención adaptadas a las características de cada grupo de edad.

En esta muestra específica, el porcentaje de casos positivos es superior en el rango de edad que va de los 41 a 55 años.

Cantidad de horas trabajadas por grupo etario




Figura 33 - Horas de trabajo por rango de edad. Fuente: elaboración propia.

También se analizaron los promedios de horas trabajadas por semana por grupo etario. En la gráfica se ven en rojo las personas con burnout y en azul sin burnout y su promedio de horas trabajadas por edad. Con esto se pretendía identificar si la cantidad de horas trabajadas podía tener influencia en el cansancio laboral, sin embargo, se encontró que las personas con mayor carga laboral presentaban menores niveles de burnout.

Burnout por Condición de Empleo




Figura 34 - Burnout por condicional laboral. Fuente: elaboración propia.

La gráfica muestra la distribución de personas con y sin burnout según su condición de empleo. Se observa que la mayor parte de los registros se concentra en las personas empleadas y autoempleadas. Por eso, estos dos grupos también presentan la mayor cantidad de casos con burnout.

En el grupo de personas empleadas y autoempleadas se observan 49.3% casos con burnout y 42.9 sin burnout. Esto puede ser un hallazgo interesante para revisar con más detalle, aunque no debe interpretarse como una causa directa.

La vista también incluye filtros por rango de edad y género. Estos filtros permiten analizar la información de forma más específica, por ejemplo, revisando si el comportamiento cambia entre hombres y mujeres o entre distintos grupos de edad. Esto es útil porque los resultados generales pueden variar cuando se observan segmentos concretos de la muestra.

En conjunto, la gráfica permite entender cómo se distribuye el burnout según la condición laboral y, al mismo tiempo, explorar diferencias por edad y género. Esto ayuda a que el análisis no se quede solo en una lectura general, sino que permita identificar posibles patrones dentro de grupos específicos.

Burnout por tamaño de comunidad




Figura 35 - Burnout por tamaño de comunidad. Fuente: elaboración propia.

Por el tamaño de la comunidad permite analizar la relación entre el entorno social y el nivel de burnout. Se calcula como el promedio de la variable Burnout_Score para cada categoría de community size, lo que permite interpretar los resultados como proporciones comparables entre distintos contextos poblacionales.

Este análisis evidencia que el entorno en el que se desenvuelve el individuo puede influir en su nivel de desgaste laboral, ya sea por factores asociados a la dinámica urbana, el acceso a recursos o las condiciones sociales. Las diferencias observadas entre comunidades pequeñas, medianas y grandes permiten identificar posibles patrones contextuales en la distribución del burnout. Adicionalmente incorpora una visión complementaria al análisis, integrando el componente ambiental y facilitando una comprensión más integral del fenómeno.

Mapa de burnout por estado




Figura 36 - Burnout por estado. Fuente: elaboración propia.

El análisis del **burnout por estado** analiza la distribución geográfica del burnout e identifica posibles concentraciones territoriales del fenómeno. Se construye a partir del promedio de la variable *Burnout sobre la muestra* que se genera de dividir el conteo de personas positivas dentro del estado entre el conteo de la

muestra total del estado. Cada categoría de **Federal State** permite interpretar los resultados como proporciones comparables entre distintas ubicaciones.

La representación en formato de mapa facilita la identificación visual de patrones espaciales, permitiendo detectar regiones con mayor o menor nivel de burnout. Este enfoque permite una dimensión adicional al análisis, integrando el componente geográfico y facilitando la interpretación de posibles diferencias regionales, contribuyendo a una comprensión más integral del fenómeno, permitiendo identificar áreas donde podrían concentrarse mayores niveles de riesgo y apoyando la toma de decisiones desde una perspectiva territorial.

En el gráfico se observó que Bavaria es el estado con más casos de Burnout con un 22,7%, mientras que los otros estados presentan un porcentaje variado.

Gráfico por Género




Figura 37 - Burnout por género. Fuente: elaboración propia.

Finalmente, el gráfico de Burnout por género ilustró una diferencia importante entre ambos grupos masculino y femenino, siendo el 13.6 % de los hombres positivos contra un 39,7% de las mujeres positivas. Sin embargo, cabe destacar que la muestra de mujeres resultó ser muy predominante dentro del set de datos y eso podría afectar el análisis.

Justificación del diseño

El diseño del dashboard se planteó con una lógica de lectura de lo general a lo específico. Primero se presentan los indicadores generales y posteriormente se habilita una que historia que nos permite analizar por área de trabajo, tipo de empleo, edad, tamaño de comunidad y ubicación geográfica.

La selección de gráficos responde a criterios de claridad y comparabilidad. Las barras permiten contrastar categorías de manera directa; el mapa facilita la lectura territorial; y los filtros permiten explorar escenarios específicos sin perder la visión global del análisis.

El uso del color se mantiene intencional y moderado, privilegiando tonos que ayuden a identificar niveles de riesgo sin saturar la visualización. Esta decisión favorece una lectura ejecutiva del dashboard y reduce la posibilidad de interpretaciones confusas.

Campos calculados.

A continuación, se describen algunas de las variables calculadas.

Clasificación Burnout: Permite Renombrar los datos positivos (1) y negativos (0) como con burnout y sin burnout para uso en gráficos

```
IF [Burnout Score] = 1 THEN "Con Burnout"
ELSE "Sin Burnout"
END
```

Horas de Trabajo: Permite nombrar los rangos de horas trabajadas para uso en gráficos.

```
IF [Working Hours] < 20 THEN "Less than 20"
ELSEIF [Working Hours] <= 41 THEN "21-40"
ELSEIF [Working Hours] <= 61 THEN "41-60"
ELSEIF [Working Hours] <= 81 THEN "61-80"
ELSE "Over 80"
END
```

Rango de Edad: Permite categorizar los rangos de edad.

```
IF [Age] < 25 THEN "Under 25"
ELSEIF [Age] <= 40 THEN "25-40"
ELSEIF [Age] <= 55 THEN "41-55"
ELSEIF [Age] <= 65 THEN "56-65"
ELSE "65+"
END
```

Porcentaje de Burnout: Calcula el porcentaje total de positivos con burnout.

```
SUM([Burnout Score])/TOTAL(COUNT([Burnout Score]))
```

Registros Totales: Calcula el total de registros.

```
COUNT([germany.dashboard.csv])
```

Tooltips y acciones

El dashboard incorpora tooltips con enfoque interpretativo, de manera que el usuario no solo visualice un valor, sino que entienda qué representa dentro del análisis. Estos textos deben explicar el indicador, el segmento seleccionado y su utilidad para la lectura del burnout.

Asimismo, se integran acciones de filtrado que permiten seleccionar un elemento de una gráfica y actualizar el resto del dashboard. Esta interacción fortalece la exploración de datos y permite pasar de una visión general a un análisis más específico sin cambiar de herramienta.

Principales hallazgos

El análisis muestra que el burnout no se distribuye de manera uniforme, sino que presenta variaciones al observarlo por variables laborales, demográficas y contextuales. Esta diferencia entre segmentos confirma la utilidad de analizar el fenómeno desde una perspectiva multidimensional.

Se identifican diferencias por área de trabajo y estatus de empleo, lo que sugiere que ciertas condiciones del entorno de trabajo pueden estar asociadas con

mayor nivel de desgaste. De igual forma, la segmentación por edad y tamaño de comunidad contribuye una lectura complementaria sobre los grupos o contextos donde el riesgo puede ser más visible. Por otro lado, la diferencia de géneros fue representativa tanto a nivel de tamaño de muestra como de resultados. Además, el promedio de horas trabajadas no parece estar afectando de manera representativa los resultados

Estos resultados deben entenderse como hallazgos exploratorios. El dashboard no busca establecer causalidad, sino facilitar la identificación de patrones que puedan orientar decisiones preventivas, análisis más profundos o futuras líneas de investigación.

Limitaciones

El presente análisis presenta algunas limitaciones que deben considerarse al interpretar los resultados. En primer lugar, el dataset no incluye una dimensión temporal, lo que impide analizar la evolución del burnout a lo largo del tiempo.

Asimismo, la información disponible no incorpora variables más profundas de tipo psicológico u organizacional, lo que limita la capacidad de explicar el fenómeno en mayor detalle. Adicionalmente, pueden existir sesgos en la muestra que afecten la representatividad de los resultados.

Finalmente, la información geográfica es limitada en términos de granularidad, lo que restringe el alcance del análisis territorial.

Posibles mejoras

Como mejora futura, se recomienda incorporar información temporal que permita analizar la evolución del burnout a lo largo del tiempo. Esto facilitaría la identificación de tendencias, el seguimiento de cambios en los niveles de riesgo y la evaluación del efecto de posibles intervenciones dentro de la organización.

También sería conveniente integrar variables adicionales de carácter psicológico, laboral y organizacional, con el fin de enriquecer el análisis y comprender mejor los factores asociados al burnout. En etapas posteriores, esta

información podría complementarse con técnicas de analítica avanzada o modelos predictivos que permitan estimar el riesgo en distintos segmentos de la población.

Por otro lado, también convendría valorar una clasificación más detallada del burnout. En lugar de utilizar únicamente una variable binaria, como “con burnout” y “sin burnout”, se podría trabajar con una escala continua o con niveles de severidad, por ejemplo bajo, medio y alto. Esto permitiría una lectura más precisa del fenómeno y facilitaría la identificación de casos intermedios que podrían pasar desapercibidos en una clasificación binaria.

Finalmente, la automatización de la actualización de datos y la creación de dashboards especializados según el perfil de usuario podrían aumentar la utilidad práctica de la solución. Por ejemplo, un dashboard ejecutivo podría enfocarse en indicadores generales y tendencias, mientras que un dashboard para áreas de recursos humanos podría profundizar en segmentos, factores laborales y posibles señales tempranas de riesgo. De esta manera, la visualización podría evolucionar desde una herramienta descriptiva hacia un sistema de apoyo para la toma de decisiones preventivas.

Conclusiones

El desarrollo del dashboard en Tableau permitió convertir un dataset estructurado en una herramienta visual e interactiva para analizar el burnout desde distintas dimensiones. La integración de indicadores, filtros y acciones facilitó la exploración de patrones y la comparación entre segmentos.

Los resultados muestran que el burnout es un fenómeno que no puede analizarse desde una sola variable. Su comportamiento cambia al observar sectores laborales, condiciones de empleo, edad, tamaño de comunidad, género y ubicación, lo que refuerza la necesidad de un enfoque integral.

En este sentido, el trabajo evidencia el valor de las herramientas de Business Intelligence para transformar datos en información accionable. El dashboard no

solo resume información, sino que facilita la identificación de patrones relevantes relacionadas con bienestar laboral y prevención de riesgos.

Enlace para la visualización del dashboard.

[Dashboard Análisis de Burnout Grupo 11 para el TFM.](#)